

RESEARCH Open Access



基于多通道脑电图的三维CNN自动检测癫痫发作

魏晓燕¹，周琳²，陈子怡³，张良军¹，周毅^{1*}来自2018年中美卫生信息学会议 中国广州。2018年6月
28日-7月1日

摘要

背景。从临床EEG数据中自动检测癫痫发作可以减少诊断时间，便于对癫痫患者进行针对性的治疗。然而，目前的检测方法主要依靠领域专家手工设计的有限特征，这对于检测大量患者脑电图数据中的各种模式是不灵活的。此外，用于癫痫检测的传统机器学习算法不能有效地适应多通道脑电图（EEG）数据，这些数据包含时间和空间信息。最近，深度学习技术已被广泛用于执行图像处理任务，它可以从数据中学习有用的特征并自动处理多通道数据。为了提供一个有效的癫痫自动检测系统，我们提出了一个新的三维（3D）卷积神经网络（CNN）结构，其输入是多通道EEG信号。

方法。从一家中心医院收集13名患者的脑电图数据，这些数据已经过专家检查。为了在CNN中表示EEG数据，首先将EEG数据的每个通道的时间序列转换为二维图像。然后，根据不同电极之间的相互关联强度，将所有通道图像组合成三维图像。最后，利用三维核子构建了一个CNN，以预测EEG数据的不同阶段，包括发作间期、发作前期和发作期。该系统的性能被评估，并与传统的基于特征的分类器和二维（2D）深度学习方法进行比较。

结果。研究表明，在单通道和多通道的比较结果中，多通道脑电图数据可以为提高特异性和敏感性提供更多信息。而基于多通道的三维CNN的准确率超过了二维CNN和传统的信号处理方法，敏感度为88.90%，特异性为93.78%。

结论。这是首次将三维CNN应用于从EEG检测癫痫发作的努力。它提供了一种从多通道EEG信号中同时学习模式的新方法，并证明了深度神经网络与三维核的结合可以建立一个有效的癫痫检测系统。

关键词 癫痫发作检测 癫痫 三维 卷积神经网络 多通道

* 通信：zhouyi@mail.sysu.edu.cn

¹中山大学中山医学院生物医学工程系，中国广东省广州市，510080

作者信息的完整列表可在文章末尾找到



© 作者（们）。2018 **Open Access** 本文根据知识共享署名4.0国际许可协议（<http://creativecommons.org/licenses/by/4.0/>）的条款发布，该许可协议允许在任何媒体上不受限制地使用、分发和复制，但必须适当注明原作者和来源，提供知识共享许可协议的链接，并说明是否做了修改。除非另有说明，知识共享公共领域的豁免权（<http://creativecommons.org/publicdomain/zero/1.0/>）适用于本文中提供的数据。

背景介绍

癫痫发作是一个重要的临床问题[1], 脑电图 (EEG) 是研究癫痫和捕捉脑电活动变化的最突出的方法之一, 这可能表明癫痫即将发作[2]。癫痫的诊断依赖于对脑电图的人工检查, 这既耗时又容易出错。Elger和Hoppe的研究发现, 在患者记录的癫痫发作中, 只有不到一半能够准确记录, 而在长期的视频脑电图监测中, 有超过一半的发作没有被报告[3]。开发实用可靠的智能诊断算法来自动检测癫痫发作具有重要意义。虽然已经有很多人努力推动这一领域的发展, 但我们必须得出结论, 癫痫检测分析还没有进入临床实践[4]。

癫痫检测的任务包括区分癫痫发作的不同阶段, 一般分为发作间期、发作前期和发作期[5]。一般来说, 癫痫检测程序分为两部分: 特征提取和分类。目前有许多基于人工特征和机器学习分类器的技术研究[6]。一方面, 时频分析[7]、非线性动力学[8]、复杂性、同步化[9]和累积能量的增量[10]等方法被用作特征提取方法。另一方面, 机器学习分类器包括贝叶斯网、传统神经网络和支持向量机 (SVM) 等。事实上, 特征分类器工程技术已经成功地用于癫痫发作检测任务[11]。然而, 这些特征的提取是基于一组有限的和预先限定的手工工程师操作。最重要的是, 鉴于癫痫发作的特征在不同的病人中是不同的, 并且可能随时间的推移而变化, 因此, 从脑电图数据中自动提取和学习信息性特征是必要的。

过去十年中, 深度学习的最新进展在检测和预测-ive数据分析方面引起了更多的关注, 特别是在健康护理和医疗实践方面[12, 13]。它是一个强大的计算工具, 能够从数据中自动学习特征。以前的研究已经证明, 深度多层perceptron神经网络比传统方法如逻辑回归[14]和支持向量机[15]表现更好。相关研究表明, 13层深度卷积神经网络(CNN)算法在波恩大学的小型公共数据中, 准确率、特异性和灵敏度分别达到 88.67%、90.00% 和 95.00%[16]。金字塔式一维神经网络的集合

CNN模型[17]被提出来以减少记忆空间和检测时间。递归卷积神经网络学习了癫痫发作的一般空间不变性表征, 大大超过了跨患者分类器上获得的前例结果[18]。深度无监督神经网络, 如变体稀疏自动编码器 (DSAE) 被用于自动及时检测癫痫发作, 但由于稀疏策略可能会错过重要信息[19]。其他技术, 如深度信念网络、跨度学习等也被应用于癫痫检测[20, 21]。这些基于深度学习的算法奠定了癫痫检测研究的基础[22]。

尽管如此, 深度神经网络很适合用于时间序列分类[23, 24], 但要同时学习多个电极的相应信息是很困难的。多通道分析的方法之一是分别研究不同的电极, 最后将其整合[25]。另一种方法是通过二维 (2D) CNN来学习多电极, 忽略了电极之间的关系[26]。因此, 我们提出了用三维 (3D) 内核的CNN来检测癫痫发作, 这种方法是准确的, 并能根据个人的需要完全自动化。这种方法最初是为了解决二维CNN中忽略图像序列的帧间信息识别的问题。

在这项研究中, 脑电图数据的每个通道的时间序列被转换为图像。所有通道的图像因此被合并为三维图像。此外, 构建了基于三维核的CNN, 以对图像数据集的不同癫痫脑电阶段进行分类。这项工作的主要贡献如下。

- 1) 提出了一种有效的方法, 将原始EEG数据预处理成适合CNN的3D图像形式, 从而整合多通道信息。
- 2) 这是第一次将具有三维核的深度CNN应用于癫痫数据集。此外, 我们提出了指导性设置, 以帮助CNN在癫痫检测任务中表现良好。
- 3) 通过测试数据验证了三维CNN方法的性能, 与之前文献中评估的二维CNN和传统机器学习技术进行了比较。

方法

数据资源和数据准备

数据资源

本研究使用的数据来自于2013~2016年新疆医科大学第一附属医院神经内科脑电图室的癫痫患者。采样

频率为500赫兹，电极的位置为国际10-20系统。临床专家对每一次癫痫发作进行了标记。癫痫患者的具体信息见表1。

不同的癫痫发作有不同的信号特征，癫痫发作的检测性能与癫痫发作的类型有关[27]。因此，本文选择了复杂部分性发作的患者数据。实验数据包括13名患者，年龄从6岁到51岁不等。记录了159次癫痫发作。每个病人的平均发作次数为12.2次。每个病人的观察时间为24小时，总发作时间为9956秒。

数据准备

众多调查表明，发作间期和发作期之间有一个逐渐过渡的过程，这被定义为发作前阶段[28]。因此，癫痫发作的检测可以被认为是三种状态的分类。在本研究中，从临床病人那里收集的EEG数据被分为三个阶段：发作间期、发作前期和发作期，如图1所示。具体情况分别如下。

- 发作前状态。每次发作前持续一小时的片段被定义为发作前状态[29]。
- 异动状态。神经生理学专家对临床发作进行了标注。
- 发作间状态。每位患者既非发作前也非发作状态的脑电信号数据被定为发作间歇状态。

系统设计

整个研究设计由典型的模块组成（见图2）。首先，由于有多个电极，所以

表1 所收集数据的细节

身份 证	性 生 活	年 龄	渠道	国家	时间	癫痫发 作	信息 技术
1	F	36	22	AS→SS	8 h	14	654s
2	F	22	22	AS→SS	48 h	12	274s
3	F	36	22	AS→SS	8 h	14	1386s
4	F	40	22	AS→SS	24 h	6	302s
5	M	6	22	AS→SS	24 h	21	453 s
6	F	16	22	AS→SS	24 h	7	329s
7	F	16	22	AS→SS	24 h	8	254s
8	F	28	22	AS→SS	24 h	5	400s
9	F	31	22	AS→SS	24 h	9	423s
10	M	51	22	AS→SS	24 h	30	1064s
11	M	20	22	AS→SS	24 h	19	4072 s
12	M	46	22	AS→SS	24 h	6	208s
13	F	15	22	AS→SS	24 h	8	137s

备注。AS 清醒阶段，SS 睡眠阶段，IT 直觉时间

通过大脑上的电极位置，将多通道脑电时间序列构建为三维图像。三维卷积核是可调整的，以适应三维图像的输入。此外，深度CNN自动从脑电信号中学习不同阶段的模式，然后将训练模型用于测试所保留的数据。13名患者的训练和推理阶段是用一台高性能的计算机计算的。

预处理

时间窗口的选择 滑动窗口分析法通常将原始脑电图数据分割成若干段进行特征提取，包括重叠滑动窗口和非重叠滑动窗口[30]。由于EEG信号是非稳态数据，时间窗口应保证数据的稳定性。重叠滑动窗可以保证数据的连续性，但容易造成信息冗余。根据实验前的情况，发作期数据的滑动时间窗为2500点（5s），而非发作期的滑动时间窗大小为10s，不发生重叠。

三维图像重建

由于在这项工作中建立了一个三维CNN，所以不可避免地要将多通道EEG信号转换成三维阵列（就像多通道图像）。这种转换必须能够保留原始数据的大部分信息。总的来说，该程序分为两个主要步骤。首先，时间序列被形成为二维图像。为了适应CNN的内核，图像被设计成正方形，其分辨率等于点的数量（如5000*5000）。并使用图像压缩技术将图像缩小到256*256，以降低运算的复杂性。然后根据电极的相邻程度选择不同电极的连续关系[31]，并将相应的二维脑电图像融合，形成三维多通道图像。其结构为[256,256,22]，如图3所示。

拟议的三维CNN结构

三维卷积法是在视频任务的动作识别中提出的，其中最广泛使用的是C3D模型[32]。由于基于三维核的CNN还没有被用于癫痫分类，所以在文献中没有最佳的网络结构来进行再融合。因此，我们在本实验中用三维核构建了一个新的CNN结构，如表2所述，它与C3D模型不同，适用于癫痫检测。




图1 单通道脑电图记录显示了典型的大脑状态。癫痫患者的典型大脑状态包括发作前、发作中和发作后三种状态。每次发作前的一个小时前被定义为发作前状态。神经生理学专家对发作状态进行注释。既非发作前也非发作时的信号的脑电图数据定义为发作间状态。该图代表了脑电信号发作的整个过程

特征提取 卷积神经网络是一种具有空间不变性特征的神经网络。此外，三维卷积层具有收集空间-时间信息的能力，在每次卷积运算后都能保留输入信号。我们根据经验发现，在有限的一组探索过的架构中，所有层的 $3 \times 3 \times 3$ 卷积核效果最好。该架构显示在图4中。如实验中所所述，三维卷积核的大小为 $3 \times 3 \times 3$ ，步长为 $1 \times 1 \times 1$ ，采用Leaky Rectified Linear Unit (ReLU) 激活函数，其系数设置为0.01。池层使用最大池，大小为 $2 \times 2 \times 2$ 。第一层的步长为 $2 \times 2 \times 2$ ，其余各层为 $1 \times 2 \times 2$ ，减少了特征的衰减。第三层直接连接到第四层，以尽可能保留信道特征信息，全连接层为4096单元和2048单元。最后，softmax分类器被用于癫痫分类任务。我们的模型是用Python 2.7和Tensor flow 1.6.0实现的。

减少过拟合阶段 由于可用的数据集有限，防止CNN过拟合并提高模型的性能是很重要的。首先，采用平等的三阶段数据集。然后，在两个全连接层中都应用了dropout策略。剔除策略使得一些隐藏层节点的权重发生了变化。第三，考虑到历时的大小，He[33]提出的组归一化将批归一化算法[34]重新置于三维CNN中。组归一化可以将数据分为几组，然后计算每组的平均值和方差。它提高了网络的泛化能力并加速了模型的收敛。比较结果见表3。

分类阶段 在这个阶段，每个CNN分支可以从不同阶段学习特征。几个分支的输入是在三维图像重新构建阶段处理的数据。在特征提取阶段和减少过拟合阶段之后，每个CNN分支获得的特征都可以被用来进行分类。


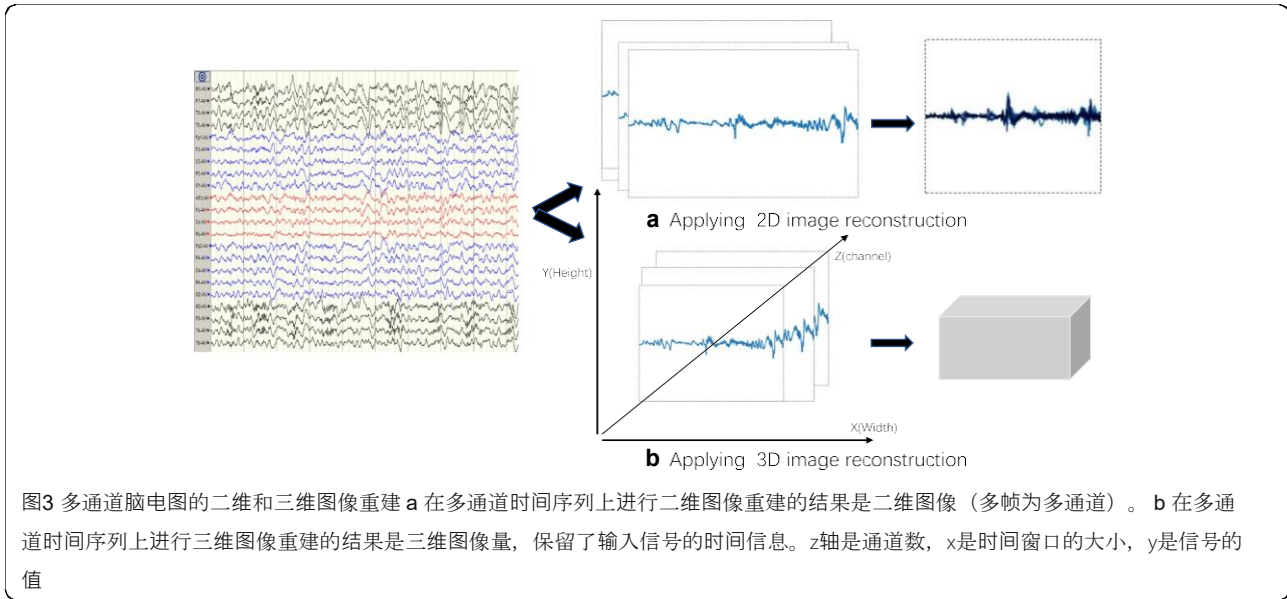


图2 使用三维CNN检测癫痫发作的管道概述



分支被合并。该模型的输出是预测的类别标签。

训练和推理阶段 总共36000张图像数据集被分成训练数据集（30000张图像）、验证数据集（3000张图像）和测试数据集（3000张图像）。训练数据集被用来训练模型的参数。验证样本用于验证该模型。测试数据集被用来评估训练后的模型。

分类程序包括训练阶段和推理（测试）阶段。在训练阶段，我们使用10倍交叉验证策略训练我们的模型。数据集被随机打乱并分成10个相等的部分。其中一个被选为验证数据集以验证模型，其余的为训练集以完成训练过程，每个折叠数据都经过验证。该

这种方法的目的是为了防止CNN模型在训练过程中的过度拟合。在推理阶段，独立测试数据被用来评估模型的性能。

根据前期的实验，我们提出了结构化的设置，以帮助CNN在癫痫检测任务中表现良好。批量大小被设定为10，一个epoch迭代为6000次，总共训练了200个epoch。选择交叉熵损失函数作为成本函数，使用自适应模态估计（Adam）优化器（初始学习率=0.01， $\beta_1=0.9$ ， $\beta_2=0.999$ ，衰减=0）。对于学习率策略：如果连续10个纪元，当验证集的误差保持不变时，当前的学习率将减少10倍。否则，学习率将在每个40个纪元。重复上述三个操作，直到训练所有的历时。

表2 3D CNN的参数

图层隐藏 图层相关参数（内核、内核大小、跨度、落差）。			
1Conv3D+ LeakyReLU	64	3*3*3	1*1*1
2Max集合		2*2*2	2*2*2
3Conv3D+ LeakyReLU	128	3*3*3	1*1*1
4Max集合		2*2*2	1*2*2
5Conv3D+ LeakyReLU	256	3*3*3	1*1*1
6Conv3D+ LeakyReLU	256	3*3*3	1*1*1
7Max集合		2*2*2	1*2*2
8完全连接	4096		
9完全连接	2048		

润彩客网




图4 3D CNN的结构。3D CNN网络有4个卷积层，3个最大集合层，2个全连接层，然后是一个softmax输出层。所有的conv3D核都是3*3*3，两个三维的跨度都是1；所有的池化层核都是2*2*2。第一个全连接层有4096个输出单元，第二个全连接层有2048个输出单元

对比二维CNN结构

在计算机视觉的帮助下，二维CNN发展迅速，代表性的卷积神经网络工作主要包括LeNet、AlexNet、Inception、ResNet、DenseNet、Xception、MobileNet、ShuffleNet、Capsule网络等。[35].我们构建了表4和图5中所示的12层二维CNN结构。对于特征提取阶段，最不同的是二维卷积层，用于收集脑电图像信息，每一个卷积层都采用批量归一化，以减少内部神经元的分布变化。为了减少过拟合阶段，全连接层采用了辍学策略，辍学率为0.5。在训练阶段，包括收益率、历时和成本函数等的设置与三维CNN相同。

系统评估

为了评估癫痫检测性能，我们使用了表5中的指标[36]。

采用包括灵敏度、特异性和准确性在内的标准测量方法来评价该模型。根据上述性能参数，评价指标被定义为：

准确率 $\frac{1}{4} TP \div FN = TP \div TN \div FP \div FN$ $\delta 1p$

特异性 $\frac{1}{4} TN = TN \div FP$ $\delta 2p$

敏感度：召回率或真阳性率 $\frac{1}{4} TP = TP \div FN$ $\delta 3p$

假阴性率FNR $\frac{1}{4} FN = TP \div FN$ $\delta 4p$
 $\frac{1}{4} 1 - \text{sensitivity}$

表3 批量规范化和分组规范化的比较

方法批量大小=10			
	纪元=1纪元=50纪元=200纪元		
孟加拉语	74%	84%	89%
辽宁省	79%	87%	90%

BN 批量归一化，**GN** 组归一化。黑体数字代表该列中最大的数字

假阳性率 $\delta FPR \div \frac{1}{4} FP = FP \div TN$

$\frac{1}{4} 1 - \text{特异性}$

$\delta 5p$

结果

本文用二维CNN模型分别测试了单电极EEG数据和多电极EEG数据，并测试了三维CNN模型，以证明三维核与其他方法相比的功效。结果显示在表6、7和8中。

根据表6，基于单电极数据测试的网络工作的准确率为89.95%，FNR为15.07%，FPR为7.53%。而多通道的准确率为89.91%，FNR为15.13%，FPR为7.57%。这表明，更多的脑电图数据携带更多的信息，可以提高医学分析的特异性和敏感性。

在表7中，基于多通道的3D CNN的准确率为92.37%，FNR为11.43%，FPR为6.22%。而2D CNN的准确率为89.91%，FNR为15.13%，FPR为7.57%。3DCNN模型的总体识别率高于2D CNN，对发作时间段的识别率最高，其次是对发作前脑电数据的识别率。

表8列出了基于3D CNN的算法与传统机器学习算法以及2D CNN的比较，所有上述方法都用本研究中使用的数据进行了训练和测试。根据结果，本文提出的方法不仅取得了最好的性能，而且还减少了手工设计的时间。

讨论

患有未受控制的癫痫的人在发作时遭受不确定性，由于医疗服务有限，在偏远地区缺乏对癫痫发作的诊断[37]。为了有效地检查癫痫病人，我们希望开发一个自动检测癫痫发作的系统来指导医生。

表4 2D CNN结构的细节

图层隐藏 图层相关参数（内核、内核大小、跨度、落差）。

1Conv2D + LeakyReLU+BN	32	5*5	1
2Max集合		3*3	2
3Conv2D + LeakyReLU+BN	64	3*3	1
4Max集合		2*2	2
5Conv2D + LeakyReLU+BN	128	3*3	1
6Max集合		2*2	2
7Conv2D + LeakyReLU+BN	256	3*3	1
8Max集合		2*2	2
9Conv2D + LeakyReLU+BN	256	3*3	1
10Max集合		2*2	2
11完全连接	2048		
辍学	0.5		
12完全连接	1024		
辍学	0.5		
润彩客网			

深度学习开启了医疗卫生领域智能诊断的新大门，尤其是在脑电信号处理方面。LSTM网络能够预测所有185次发作，在公共数据集中提供了基于不同发作前时间窗口的高比率的发作预测灵敏度[38]。所提出的深度学习方法结合了时间频率和CNN，在公共数据集中实现了81.4、81.2和75%的敏感度。

数据集[39]。应用于隐藏层的深度学习使数据的表达尽可能具体化，以便获得更有效的EEG信号的表示。

然而，大多数深度学习研究采用二维网络，忽略了多通道信号处理的事实[40]，表6显示，更多通道的EEG信号可以提高性能。




表5 预测结果和实际结果的混淆矩阵

		预测		共计
		宗旨	非物体	
实际情况	物体 非物	真阳性(TP) 假阴	假阳性(FP) 真阴	tp + fp
	体	性(FN)	性(TN)	fn + tn
共计		TP + FN	FP + TN	tp + fp + fn + tn

矩阵的每一行代表预测类中的实例，而每一列代表实际类中的实例。

网络。我们提出了三维图像重构的方法来关联多通道信息，就像在视频处理中一样[41]。此外，我们还采用了分组归一化以及超采样技术来克服有限数据集的过拟合问题[42]。与表7所示的二维CNN相比，我们的策略取得了超过90%的平均精度。这表明有一个可靠的和自动的癫痫发作检测系统。这是第一个将三维核CNN引入癫痫检测的研究。

为了评估我们的方法，我们对所提出的算法与使用相同数据的三项研究进行了衡量，总结在表8中。第一种方法[43]从EEG数据中提取预定义的特征，并使用传统的机器学习技术对癫痫阶段进行分类。这需要很多时间，而且有可能在选定的特征中完全或部分地遗漏一些信息。接下来的两种深度学习方法，包括二维CNN和三维CNN，它们可以自动学习数据模式。平均而言，所提出的3D CNN方法在多通道信息方面的表现比2D CNN好，它以较少的时间和较高的准确率超过了手工设计的方法。最近在Kaggle上举行的癫痫检测比赛中，前三名获胜的算法[44]包括手工设计的方法和深度学习的方法，但他们都是依靠复杂的features选择的。因此，这里提出的方法可以在一个在线平台上运行，并在更多的数据上进行测试，满足了权力、资源和

可以在穿戴式设备中实现的计算。

然而，这项工作的局限性是必须承认的。首先，这种方法，所有的深度学习技术都需要足够的数据来训练模型，而且网络的design更难保证是最佳的。也许其他研究只需调整小参数就能获得更好的性能。第二，一个中心的少数临床专家对模型数据进行标注。第三，该实验只涉及脑电图数据类型，从多尺度的角度忽略了其他数据类型。为了有一个更普遍的临床评价，这些方法应该在一个广泛的多中心数据集上进行测试。更多的相关信息源可以随时纳入深度神经网络，如视频、天气模式、生物标志物或临床笔记[45, 46]。纳入这些额外输入和数据类型的检测算法是目前工作的重点。

总结

本研究提出了一种新的癫痫性脑电图分类方法，该方法针对多通道脑电图数据构建了三维CNN。该方法的主要优点是充分利用了多通道信号信息，无需手工设计。三维CNN模型的表现优于之前的启发式检测器。据我们所知，本研究是首次尝试使用三维CNN算法进行癫痫发作检测。因此，它可以作为探索多通道EEG数据方面的深度学习启用的癫痫检测的新工作的基准。进一步的研究需要进行

表6 基于2DCNN模型使用单通道和多通道的分类结果

		预测			准确度	特异性	敏感度
		发作间期	发作前	发 作			
单通道	发作间期	813	124	63	87.53%	90.65%	81.30%
	发作前	92	864	44	90.20%	92.1%	86.40%
	Ictal	95	34	871	92.13%	94.65%	87.10%
多渠道	发作间期	822	119	59	88.13%	91.10%	82.20%
	发作前	107	838	55	89.20%	91.90%	83.80%
	Ictal	71	43	886	92.40%	94.30%	88.60%

表7 基于2D和3DCNN模型使用多电极的分类结果

		预测			准确度	特异性	敏感度
		发作间期	发作前	发作			
3D CNN	发作间期	861	81	58	90.73%	93.05%	86.10%
	发作前	77	894	29	92.57%	94.15%	89.40%
	Ictal	62	36	902	93.83%	94.15%	90.20%
2D CNN	发作间期	822	119	59	88.13%	91.10%	82.20%
	发作前	107	838	55	89.20%	91.90%	83.80%
	Ictal	71	43	886	92.40%	94.30%	88.60%

在多中心的数据集中验证这种算法。我们期望在信号处理、网络设计、模型验证方面有更多的进展，以塑造自动发作检测的未来。

缩略语

二维：二维；三维：三维；ApEn。近似熵；AS：清醒阶段；CNN。卷积神经网络；DWT：离散小波变换；EEG：脑电图；IT：直角时间；ReLU。整理的线性单元；SS：睡眠阶段；SVM。支持向量机

鸣谢

作者要感谢张震有见地的讨论和语言帮助。作者还感谢匿名审稿人的仔细审查和宝贵意见。

资助

本研究/工作得到了国家自然科学基金[No.61876194]、国家重点研发计划[No.2018YFC0116902, No.2018YFC0116904、No.2016YFC0901602]、国家自然科学基金委和广东省大数据科学中心联合基金（No.U1611261）、广州市科技计划项目[No.201604020016]、惠州市科技计划项目[No.2014B010118003]和广东省自然科学基金[No.2018A030313345]。本文未获得发表的资助。

数据和材料的可用性

所有的数据都是从入院的病人那里收集的，由于医院的规定，这些数据不能公开提供。

关于本补充剂

本文已作为《BMC医学信息学与决策》第18卷补编5，2018年的一部分发表。来自2018年中美健康信息学会议的论文集。该增刊的全部内容可在线查阅：<https://bmcmidinformedecismak.biomedcentral.com/articles/supplements/volume-18-supplement-5>。

作者的贡献

研究概念和数据提供。YZ、XYW和ZYC。数据准备和处理。XYW模型的制定。LZ、XYW和YZ。撰写和修改

表8 不同方法的性能比较

方法	平均精度	运行时间
ApEn+DWT+SVM [43]。	91.25%	85.1 s
2D CNN	89.91%	3.8 s
3D CNN	92.37%	8.6 s

SVM 支持向量机, ApEn 近似熵, DWT 离散小波变换 粗体数字表示该列中最大的数字

稿件。XYW和LJ Z稿件的审核。LZ, ZYC 和 YZ。所有作者都阅读并批准了稿件的最终版本。作者声明，他们没有竞争性利益。

伦理批准和参与同意
不适用。

同意出版
不适用。

有竞争性的利益
作者声明，他们没有竞争性利益。

出版商的说明

斯普林格-自然公司对已出版的《自然》杂志中的管辖权要求保持中立。地图和机构隶属关系。

作者详情

¹中山大学中山医学院生物医学工程系，中国广东省广州市，510080。
²中山大学计算机与数据科学学院软件工程系，广东省广州510006。³中山大学附属第一医院神经科，中国广东省广州市，510080。

发布时间：2018年12月7日

参考文献

1. Jory C, Shankar R, Coker D, Mclean B, Hanna J, Newman C. Safe, and sound? 个人使用的癫痫检测方法的系统性文献回顾。 *Seizure*.2016;36:4-15.
2. Beniczky S, Ryvlin P. 癫痫检测设备的测试和临床验证的标准。 *Epilepsia*.2018; 59(Suppl 1):9.
3. Elger CE, Hoppe C. 癫痫病的诊断挑战：癫痫发作报告不足和癫痫发作检测。 *Lancet Neurol*.2018;17(3):279-88.
4. Mormann F, Andrzejak RG.癫痫预测：在漫长而曲折的道路上创造里程。 *Brain*.2016;139(6):1625-7.
5. Trinka E, Kälviäinen R. 25年来在癫痫状态的定义、分类和治疗方面的进展。 *Seizure Eur J Epilepsy*.2017;44:65.
6. Cogan D, Birjandtalab J, Nourani M, Harvey J, Nagaraddi V. 用于癫痫发作监测的多重生物信号分析。 *Int J Neural Syst*.2016;27(01):345-55.
7. Fiscon G, Weitschek E, Cialini A, Felici G, Bertolazzi P, Salvo SD, et al. Combining EEG signal processing with supervised methods for Alzheimer's patient's classification. *BMC Med Inform Decis Mak*.2018;18(1):35.
8. Zhou Y, Huang R, Chen Z, Chang X, Chen J, Xie L. 近似熵在癫痫失神发作动态特征上的应用。 *Neural Regen Res*. 2012; 07(8):572-7.
9. Gao ZK, Cai Q, Yang YX, Dong N, Zhang SS.来自自适应最优核时频表示的可见度图用于癫痫样脑电的分类. *Int J Neural Syst*.2017;27(4):1750005.
10. Gigola S, Ortiz F, D'Attellis CE, Silva W, Kochen S. 使用多分辨率框架

approaches.2018.

11. Subasi A, Gursoy MI.使用PCA、ICA、LDA和支持向量机进行脑电信号分类。Expert Syst Appl. 2010; 37(12): 8659-66.
12. Litjens G, Kooi T, Bejnordi BE, Aaa S, Ciompi F, Ghafoorian M, et al. A survey on deep learning in medical image analysis.Med Image Anal.2017;42(9):60-88.
13. Xun G, Jia X, Zhang A. 通过上下文学习模型用脑电图检测癫痫发作。BMC Med Inform Decis Mak.2016;16(2):70.
14. Subasi A, Erçelebi E. 使用神经网络和逻辑回归对EEG信号进行分类。Comput Methods Programs Biomed.2005;78(2):87-99.
15. Mirowski PW, Lecun Y, Madhavan D, Kuzniecky R, editors.比较SVM和卷积网络对颅内EEG的癫痫发作的预测。信号处理的机器学习, 2008 MLSP 2008 IEEE研讨会 ; 2008。
16. Acharya UR, Oh SL, Hagiwara Y, Tan JH, Adeli H.使用EEG信号自动检测和诊断癫痫发作的深度卷积神经网络。Computers in biology and medicine.2018; 100:270-8.
17. Ullah I, Hussain M, Qazi EUH, Aboalsamh H. An automated system for epilepsy detection using EEG brain signals based on deep learning approach.Expert Syst Appl. 2018; 107:61-71.
18. Thodoroff P, Pineau J, Lim A. Learning robust features using deep learning for automatic seizure detection; 2016.
19. Lin Q, Ye S-q, Huang X-m, Li S-y, Zhang M-z, Xue Y, Chen W-S.基于深度学习的堆叠稀疏自动编码器对癫痫性脑电信号的分类。InInternational Conference on Intelligent Computing: 2016:802-810.
20. Movahedi F, Coyle JL, Sejdić E. Deep belief networks for electroencephalography:最近的贡献和未来的展望的回顾。IEEE J Biomed Health Inform.2017;PP (99) : 1。
21. Jiang Y, Wu D, Deng Z, Qian P, Wang J, Wang G, et al. Seizure Classification from EEG Signals using Transfer Learning, Semi-Supervised Learning and TSK Fuzzy System.IEEE Trans Neural Syst Rehabil Eng. 2017; PP(99):1.
22. Zhang Q, Yang LT, Chen Z, Li P. A survey on deep learning for big data.Inf Fusion.2018;42:146-57.
23. Gupta A, Singh P, Karlekar M. A Novel Signal Modeling Approach for Classification of Seizure and Seizure-free EEG Signals.IEEE Trans Neural Syst Rehabil Eng. 2018;PP (99) :1.
24. Makinson CD, Tanaka BS, Sorokin JM, Wong JC, Christian CA, Goldin AL, 等. Scn8a对丘脑和皮质网络同步的调节。Neuron.2017;93(5):1165–79.e6.
25. Paesschen WV.癫痫检测的未来。Lancet Neurol.2018;17(3):200-2.
26. Quigg M, Leiner D. 额头上的单通道脑电图对新生儿癫痫发作检测的限制。J Perinatol.2009;29(3):237-42.
27. Uate-Campos A, Coughlin F, Gainza-Lein M, Fernández IS, Pearl P, Loddenkemper T. 自动化癫痫检测系统及其对每种类型癫痫的有效性。Seizure.2016;40:88-101.
28. Cook MJ, O'Brien TJ, Berkovic SF, Murphy M, Morokoff A, Fabinyi G, et al. 预测耐药性癫痫患者的长期、植入式发作咨询系统的发作可能性：一项首次人体研究。Lancet Neurol.2013;12(6):563-71.
29. Bandarabadi M, Rasekhi J, Teixeira CA, Karami MR, Dourado A. On the proper selection of preictal period for seizure prediction.Epilepsy Behavior.2015;46:158.
30. Zhang Z, Chen Z, Zhou Y, Du S, Zhang Y, Mei T, et al. Construction of rules for seizure prediction based on approximate entropy.Clin Neurophysiol. 2014; 125(10):1959-66.
31. Weis JA, Miga MI, Yankeelov TE.基于三维图像的机械建模, 预测乳腺癌对新辅助治疗的反应。Comput Methods Appl Mech Eng. 2016; 314:494-512.
32. Du T, Bourdev L, Fergus R, Torresani L, Paluri M, editors.用三维卷积网络学习时空特征。IEEE国际计算机视觉会议 ; 2016年。
33. Crytzer TM, Keramati M, Anthony SJ, Cheng Y-T, Robertson RJ, Dicianno BE. 在患有脊柱裂的青少年和成人中, 使用群体标准化的感知疲劳评分来制定运动处方。PM&R.2018;10(7):738-47.
34. Ioffe S, Szegedy C. Batch normalization: accelerating deep network training by reducing internal covariate shift; 2015. p. 448-56.
35. Alom MZ, Taha TM, Yakopcic C, Westberg S, Hasan M, Essen BCV, et al. The history began from AlexNet: a comprehensive survey on deep learning

36. Assi EB, Dang KN, Rihana S, Sawan M. Towards accurate prediction of epileptic seizures: a review. *Biomed Signal Process Control*.2017;34:144-57.
37. Ryvlin P, Beniczky S. 癫痫的发作检测和移动健康设备。更新和未来的发展。 *Epilepsia*.2018;59:7-8.
38. Tsiouris KM, Pezoulas VC, Zervakis M, Konitsiotis S, Koutsouris DD, Fotiadis DI. 利用EEG信号预测癫痫发作的长短期记忆深度学习网络。 *Computers in biology and medicine*.2018;99:24-37.
39. Truong ND, Nguyen AD, Kuhlmann L, Bonyadi MR, Yang J, Ippolito S, Kavehei O. 使用颅内和头皮脑电图的卷积神经网络预测癫痫发作。 *Neural Networks*.2018;105: 104-111.
40. Denmark T, Fridrich J, Comesañaalfaro P. Improving selection-channel-aware steganalysis features. *Electron Imaging*.2016;2016(8):1-8.
41. Ji S, Xu W, Yang M, Yu K. 3D卷积神经网络用于人类动作识别。 *IEEE Trans Pattern Anal Mach Intell*.2012;35(1):221-31.
42. Brinkmann BH, Wagenaar J, Abbot D, Adkins P, Bosshard SC, Min C, et al. Crowdsourcing reproducible seizure forecasting in human and canine epilepsy. *Brain*.2016;139(6):1713-22.
43. Kumar Y, Dewar ML, Anand RS. 使用基于DWT的ApEn和人工神经网络检测脑电图中的癫痫发作。 *SIVIP*.2014;8(7):1323-34.
44. Baldassano SN, Brinkmann BH, Ung H, Blevins T, Conrad EC, Leyde K, et al. Crowdsourcing seizure detection: algorithm development and validation on human implanted device recordings. *Brain A J Neurol*.2017;140(6):1680.
45. Kiral-Kornek I, Roy S, Nurse E, Mashford B, Karoly P, Carroll T, et al. Epileptic seizure prediction using big data and deep learning: toward a Mobile system. *EBiomedicine*.2017;27(C):103-11.
46. Schneider JM, Maguire MJ. 识别震荡动力学和事件相关反应之间的关系。 *International Journal of Psychophysiology*.2018;133:182-192.

Ready to submit your research? Choose BMC and benefit from:

- fast, convenient online submission
- thorough peer review by experienced researchers in your field
- rapid publication on acceptance
- support for research data, including large and complex data types
- gold Open Access which fosters wider collaboration and increased citations
- maximum visibility for your research: over 100M website views per year

At BMC, research is always in progress.

Learn more biomedcentral.com/submissions

