









研究文章

利用脑电图信号对癫痫发作进行鲁棒性检测的新型深度神经网络

赵 ¹ 赵文兵 ² 王文峰 ³ 蒋晓露 ¹ 张晓东 ¹
, ⁴ 彭永红 ⁵ 张宝灿, ¹ 和张国凯 ⁶

¹集美大学诚毅学院, 厦门361021, 中国

²Department of Electrical Engineering and Computer Science, Cleveland State University, Cleveland, Ohio 44115, USA³
School of Electronic and Electrical Engineering, Shanghai Institute of Technology, Shanghai 200235, China⁴ Department
of Ultrasound, The First Affiliated Hospital of Xiamen University, Xiamen 361005, China

⁵桑德兰大学计算机科学学院, 桑德兰, 英国

⁶同济大学软件工程学院, 上海201804, 中国

通讯作者: Wenfeng Wang; wangwenfeng@sit.edu.cn, Xiaodong Zhang; zxdon11@163.com, and Guokai Zhang;
zhangguokai_01@163.com

2020年2月2日收到; 2020年3月6日接受; 2020年4月7日发表

特邀编辑: 蒋一章

Copyright © 2020 Wei Zhao et al. 这是一篇开放获取的文章, 在知识共享署名协议下发布, 该协议允许在任何媒体上无限制地使用、分发和复制, 但须适当引用原作。

脑电图 (EEG) 片段中记录的癫痫发作活动的检测对于癫痫发作的分类至关重要。人工识别是一个费时费力的过程, 给神经科医生带来了沉重的负担, 因此, 癫痫的自动识别已成为一个重要问题。传统的脑电图识别模型在很大程度上依赖于人工经验, 其概括能力较弱。为了打破这些限制, 我们提出了一种新型的一维深度神经网络, 用于稳健检测癫痫发作, 它由三个卷积块和三个全连接层组成。其中, 每个卷积块由五种类型的层组成: 卷积层、批量规范化层、非线性激活层、剔除层和最大集合层。模型的性能在波恩大学的数据集上进行了评估, 在两类分类问题上达到了97.63%~99.52%的准确率, 在三类EEG分类问题上达到了96.73%~98.06%, 在复杂的五类问题上达到了93.55%。

1. 简介

脑电图 (EEG) 是一种无创的、effective的技术, 用于临床研究以解码大脑的电活动。脑电图是识别大脑异常的关键技术之一, 如检测癫痫发作。癫痫发作是由大脑神经元异常和过度超同步放电引起的短暂的神经系统功能紊乱。由神经科专家目测脑电图检测癫痫发作是一个费时费力的过程, 由于脑电图数据量大, 且不同的神经科专家的临床判断标准不一, 诊断可能不准确[1, 2]。因此, 基于脑电图的癫痫检测的科学研究引起了广泛关注。

文献中提出了许多用于自动检测癫痫发作的算法。这些方法可以大致分为两类: 传统方法和基于深度学习 (DL) 的方法。其中, 大多数传统方法使用手工设计的技术从脑电信号中提取特征, 然后与分类器结合起来进行识别。波恩大学的脑电图数据库被广泛使用, 它是公开的, 并被标记为A、B、C、D和E, 数据集的细节在后面的章节中描述。使用波恩数据集进行癫痫检测的工作已经发表了很多。它们涉及三个主要的分类问题: 两类癫痫检测问题侧重于非癫痫发作和癫痫发作之间的分类; 三类癫痫分类问题侧重于癫痫的分组。

三种不同的EEG类别（正常、发作间期和发作期）；而五类识别问题侧重于五种不同类型（A、B、C、D和E）的分类。

2009年，Ocak[3]提出了一个基于近似熵和离散小波变换（DWT）的脑电信号检测癫痫发作的方案。这个框架在两类脑电图分类中获得了96%的准确性。此外，Tzallas等人[4]证明了时频分析（TFA）适合于对癫痫发作的脑电图区进行分类。作者采用人工神经网络（ANN）作为分类器，两类和三类分类的准确率为100%，五类分类的准确率为89%。2010年，Subasi和Ismail Gursoy[5]采用主成分分析、独立成分分析和线性判别分析来降低脑电信号的维度，从DWT中提取统计特征，然后使用支持向量机（SVM）进行分类。该模型在两类分类中获得了100%的癫痫检测准确率。2011年，Orhan等人[6]使用k-means算法对小波系数进行聚类，然后用多层感知器神经网络（MLPNN）进行分类。该模型产生的两类和三类分类的最大准确率分别为100%和96.67%，再光谱。2012年，Acharya等人[7]提出了一种从EEG信号中自动检测正常、发作间期和发作类别的方法。他们提取了四个基本特征，然后将其输入到一个模糊分类器。该方法达到了98.1%的准确率。2014年，Kaya等人[8]使用一维局部二进制模式（1-D-LBP）从原始EEG中提取特征，并分别与五种不同的分类器相结合，如Bayes Net、SVM、ANN、逻辑回归（LR）和功能树（FT）。表现最好的分类器是Bayes Net分类器，它在两类和三类分类中分别取得了99.5%和95.67%的最大准确率。表现最差的分类器是LR分类器，它在两类和三类分类中分别获得了96.50%和66.67%的最大准确率。2015年，Sharma和Pachori[9]提出了基于相位空间表示的癫痫发作和无发作的EEG信号分类的特征。他们采用最小二乘支持向量机作为分类器，其准确率为98.67%。2016年，Sharmila和Geethanjali[10]研究了两类癫痫检测的14种不同组合的性能。他们采用天真贝叶斯（NB）和k-近邻（KNN）分类器对来自DWT的统计特征进行分类，NB分类器在健康睁眼和癫痫脑电数据的分类中获得了100%的准确性。2017年，Zhang和Chen[1]采用局部平均分解（LMD）将原始EEG信号分解成几个乘积函数（PF），然后将这些特征送入five分类器。作者报告说，表现最好的分类器是通过遗传算法优化的SVM（GA-SVM），平均分类精度等于或高于98.1%。Bhattacharyya等人[11]通过用tunable-Q小波变换（TQWT）将信号分解为以下数量，计算了基于Q的熵。

在这个过程中，我们使用了支持向量机分类器和基于包装的特征选择方法作为分类器，并从不同的子带累积估计K-近邻熵（KNNE）。该方法在两类和三类分类中分别达到了100%和98.6%的最大效率。Zahra等人[12]提出了一种数据驱动的方法，使用多变量经验模式分解（MEMD）算法进行五类脑电分类。并采用了ANN作为分类器，其准确率达到87.2%。

这些检测癫痫发作的传统方法使用手工设计的技术从EEG信号中提取特征。这些传统方法中的许多方法在一个问题上显示出良好的准确性，但在其他问题上却表现得不尽人意[2]。例如，他们对非癫痫和癫痫发作病例（两类分类问题）的识别具有很好的准确性，但对三类癫痫分类的检测表现不佳。深度学习是机器学习的一个新的研究方向，它可以自动地学习样本数据的内在规律和特征。随着可用数据和硬件计算能力的不断提高，深度学习已经解决了越来越复杂的应用问题，其accuracy也不断提高[13-15]。最近，基于深度学习方法的癫痫发作自动检测受到广泛关注。

2018年，Acharya等人[16]实现了一个13层的深度卷积神经网络（CNN）算法来检测正常、发作前和发作类别。这个模型包括五个卷积（Conv）层、五个最大集合层和三个全连接（FC）层。在这个三类检测问题上，它的准确性、精确性和敏感性分别达到了88.67%、90.00%和95.00%。此外，Ullah等人[2]提出了一个基于金字塔式一维卷积神经网络模型集合的癫痫检测自动系统。该系统的核心部分是金字塔式一维卷积神经网络（P-1D-CNN）模型，它由三种主要类型的层组成。卷积层、批量化（BN）和FC层。P-1D-CNN模型的分类型能并不十分令人满意。因此，作者在P-1D-CNN模型的最后阶段引入了多数票（M-V）模块，这极大地提高了算法的性能。在几乎所有关于癫痫检测问题的两类和三类案例中，它的准确率都达到了90%。

$99.1 \pm 0.9\%$ 。2019年，Turk和Ozerdem[17]通过应用连续小波变换（CWT）对包含五种不同类别的EEG记录获得二维频率-时间谱图，并使用CNN结构学习谱图图像的属性。在所有涉及癫痫发作的两类、三类和五类分类问题上，其识别精度分别为98.5%~99.5%、97.0%~99.0%和93.6%。此外，Hussein等人[18]引入了一个深度长短期记忆（LSTM）网络来学习不同的EEG模式的高级表征，使用一个FC层来提取与癫痫发作相关的最稳健的EEG特征。这

该模型对两类、三类和五类分类问题的准确率达到100%。

尽管使用上述CNN模型获得了令人鼓舞的癫痫检测结果，但仍可实现若干改进。首先，其中一些CNN模型的模型结构相对单一。第二个问题是可用的样本数量少，不足以训练一个深度神经网络模型。因此，我们感到有动力开发一个CNN模型，以使用原始的EEG信号来检测seizures。为了解决这些问题，首先，我们在传统的卷积块中加入了BN层和dropout层来学习特征，这可能有助于准确地检测癫痫发作。其次，原始脑电图的片段被分成许多不重叠的块，以增加训练和测试的样本数量，这可能有助于使用少量的可用数据来充分训练一个深度模型。研究表明，所提出的方法在以下方面是有优势的
使用脑电图信号检测癫痫发作。

2. 材料和方法

2.1. 脑电数据集的描述。我们的癫痫识别实验是使用波恩大学制作的广泛使用和公开的EEG数据库进行的[19]。这个数据库由五个不同的子集（集A-E）组成，分别表示为Z、O、N、F和S。集A和B是由健康志愿者在清醒状态下睁眼和闭眼时的表面脑电图记录组成。另一方面，C、D和E组是由癫痫病人收集的。其中，C组和D组是在无癫痫发作的间歇期记录的。C组是在大脑对侧半球的海马阵中记录的。D组是在癫痫发生区内记录的。E组只包括癫痫发作活动。每组包含100个单通道的脑电信号记录，采样率为173.61赫兹，持续时间为10分钟23.6秒。相应的时间序列被采样为4097个数据点。此外，罗切斯特理工学院将每4097个数据点分为23个块。每个块包含1秒的178个数据点（<https://archive.ics.uci.edu/ml/datasets/Epileptic+Seizure+Recognition>）。为了增加训练深度模型的样本数量，我们采用了这种格式的波恩数据集，其样本量增加了22倍。因此，每个类别有2300个EEG样本。五个EEG类别的EEG信号样本显示在图1中。

2.2. 拟议网络的结构。深度CNN模型[20]可以自动学习EEG信号的特征，并以端到端的方式进行分类。本文提出的CNN整体架构如图2所示，它可以进行特征提取和分类。首先，输入的单偏心原始EEG数据被归一化为零均值和单位方差。然后，采用三个卷积块来学习脑电信号的特征，每个块由五层组成。具体来说，第一层




图1：本研究中的脑电信号样本。

并行计算多个卷积，生成一组线性激活反应。第二层是BN，用于解决内部变量的转移。每个线性激活响应都会在该层中通过一个非线性激活函数。本工作中使用的激活函数是整流线性单元（ReLU）[21]。在第四层，采用了dropout技术[22]，以防止出现过激反应。该块的最后一层是最大集合层，它引入了翻译不变性。在结构上，第二和第三层卷积块与第一层类似。

在第三个卷积块的末尾，特征图被分割成一个一维向量，连接到FC层以整合特征。前两个卷积层采用ReLU作为激活函数，然后是一个滤波层。第三个功能层采用softmax作为激活函数，它将输出一个对应于每个类别的概率向量。为了选择更好的模型参数，我们探索了具有不同规格的八个模型。详情在实验结果和讨论部分描述。在本研究中，我们选择M7模型。表1显示了拟议的CNN结构的细节。

2.3. Convolution Operation. A convolutional neural network (CNN) is a neural network designed to process data with similar network structures. The image can be regarded as a two-dimensional pixel grid. Similarly, time-series data can be considered as a one-dimensional grid formed by regularly sampling on time axis. The convolutional block of conventional CNN includes three layers: convolution, activation function, and pooling. For the one-dimensional EEG data used in this paper, the convolution operation is as follows:

$$s(t) \diamond (x * w)(t) \diamond \sum_a x(a)w(t-a). \quad (1)$$

卷积网络具有稀疏交互的特点。因此，这意味着需要存储的参数较少，这不仅降低了模型的存储要求，而且简化了计算。同时。

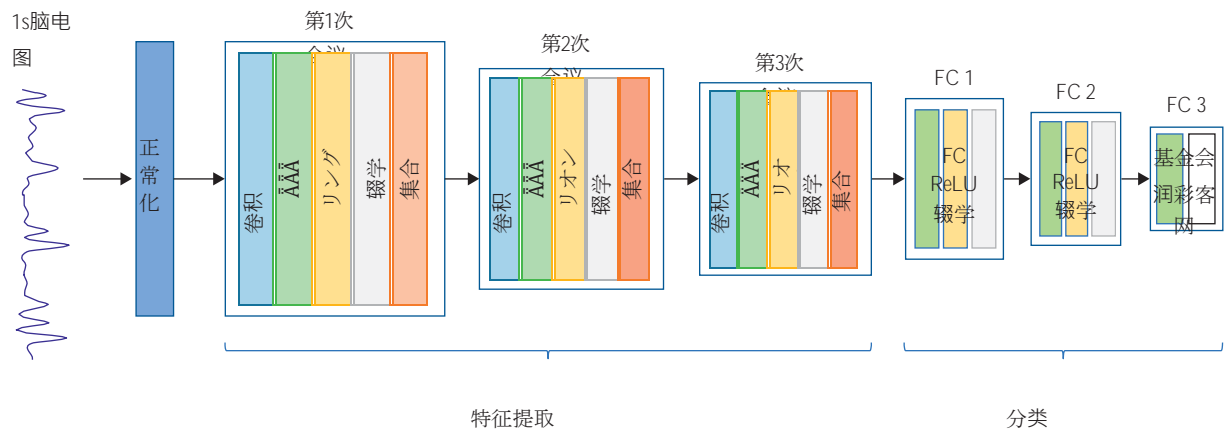


图2：提议的一维卷积神经网络架构。

表1:本研究中使用的CNN结构的细节。区块

| 会议 | 层 | 神经元 (输出层) | 芯片尺寸为 输出功能 | 并行 |
|-------------|------|--------------|---------------|----|
| 第1次会议 | 卷积 | 139 × 20 | 40 | 1 |
| | AAA | 139 × 20 | - | - |
| | 最大池化 | 139 × 20 | - | - |
| | ReLU | 70 × 20 | 2 | 2 |
| 第2次会议 | 卷积 | 51 × 40 | 20 | 1 |
| | AAA | 51 × 40 | - | - |
| | 最大池化 | 26 × 40 | -2 | 2 |
| | ReLU | 17 × 80 | 10 | 1 |
| 第3次会议 | 卷积 | 17 × 80 | - | - |
| | AAA | 17 × 80 | - | - |
| | 最大池化 | 17 × 80 | -2 | 2 |
| | ReLU | 17 × 80 | - | - |
| 基金会1 ライト | 卷积 | 17 × 80 | - | - |
| | AAA | 17 × 80 | - | - |
| | 最大池化 | 17 × 80 | - | - |
| | ReLU | 17 × 80 | - | - |
| 基金会2 ライト | 卷积 | 17 × 80 | - | - |
| | AAA | 17 × 80 | - | - |
| | 最大池化 | 17 × 80 | - | - |
| | ReLU | 17 × 80 | - | - |

卷积核共享的参数保证了或3或5我们只需要学习小很多数量级的参数。卷积是一种特殊的线性操作，而激活函数将非线性特征带入网络。直线单元（ReLU）函数是最常用的激活功能。

在CNN中的函数，它克服了梯度消失的问题，使模型能够更快地学习，表现得更好。
公式（2）显示了ReLU函数。

$$f(x) = \max\{0, x\}.$$
 (2)

集合函数可以减少表示的空间大小，以减少参数的数量和

在网络中进行计算。它取代了系统在某个特定位置的输出。例如，max-pooling给出了几个邻域的最大值。池化也可以帮助使表示法对输入的小平移近似不变。

2.4. BN的计算。在本研究中，BN层和dropout层被加入到传统的卷积块中。在训练深度神经网络时，每个层的参数都是密切相关的。各层输入分布的不一致导致了一个问题，称为内部协变量偏移。而内部协变量偏移使得我们很难选择一个合适的学习率。为了解决这个问题，Ioffe和Szegedy[23]开发了BN技术，该技术几乎可以重构任何深度网络，极大地减少了多层之间协调更新的问题。该技术将规范化作为模型架构的一部分，并对每个小批量进行规范化。

在训练过程中，BN在反向传播中计算小批量响应H的样本平均值和标准偏差，方法是

$$\mu = \frac{1}{m} \sum_i H_i$$
$$\sigma^2 = \frac{1}{m} \sum_i (H_i - \mu)^2$$
 (3)

其中delta分量δ保持在一个小的正值，只是为了避免梯度在真正的标准差为零时变得不确定。它们被用来将H归一化，即

$$H' = \frac{H - \mu}{\sigma}$$
 (4)

BN在加速训练阶段的收敛方面也非常有用，并能防止过度疲劳。该技术已经成为一种常见的做法，详细内容可以在[23]中找到。因此，我们在每个卷积层之后都采用BN。

2.5. **特征融合和分类。**深度神经网络需要学习大量的参数，这在小数据集的情况下很可能会导致过量的参数。为了解决这个问题，作者[22]开发了dropout技术来防止特征检测器的共同适应。辍学的关键思想是在训练过程中以预先设定的概率（连同其连接）从神经网络中随机剔除单元。它极大地减少了过筛，并比其他正则化方法有明显的改进。在提议的模型中，我们在每个ReLU激活函数之后添加了dropout的铺垫。

最后一个卷积块的输出表示

脑电信号中的高级特征。全连接层是学习这些特征的非线性组合的一种通常方式。最后一个最大集合层的所有神经元都与第一个FC层的所有神经元相连。我们使用了三个FC层。最后一个FC层（FC3）的神经元数量取决于检测问题，例如，对于两类、三类和五类癫痫分类概率，FC3的神经元数量分别为2、3和5。

softmax激活函数是逻辑回归的二进制形式的泛化。它通常被应用于深度神经网络的最后一层，用于构成类标签的分类分布，并获得每个输入元素属于某个标签的概率。用 $h\theta(x^{(i)})$ 表示的softmax函数被定义为方程(5)，它代表了第 i 项的各自概率。属于每个类别的样本（用 x 表示 (i) ）。

$$h\theta x^{(i)} = \frac{e^{\theta_1 x^{(i)}}}{e^{\theta_1 x^{(i)}} + e^{\theta_2 x^{(i)}} + \dots + e^{\theta_k x^{(i)}}} \quad (5)$$

其中 $\theta_1, \theta_2, \dots, \theta_k$ 是softmax模型参数。

2.6. **CNN模型的训练。**训练拟议的模型需要从脑电数据中学习权重参数。为了学习这些参数，我们采用了传统的反向传播算法，以交叉熵作为损失函数。而且，我们使用了随机梯度下降法和亚当优化器，该方法是基于一阶和二阶参数的自适应估计。Adam算法的超参数如下：学习率（0.0005），beta1（0.9）和beta2（0.999）。该模型在Keras中实现，Keras是一个强大的深度学习库，在TensorFlow的基础上运行。在这项工作中，选择了100的批次大小，用于每次训练更新。为了比较性能指标，我们用300个epochs训练了本工作中的所有模型。

2.7. **性能指标。**为了评估，我们采用了众所周知的性能指标，如准确性（Acc）。

精度（Pre）、灵敏度（Sen）和规格（Spe），F1。其中，精度是文献中最常用的指标之一，它被定义为正确分类的样本与总样本数的比率。这些性能指标的定义如下。

$$\begin{aligned} \text{累积起来的} &= \frac{tp + tn}{tp + tn + fp + fn}, \\ \text{Pre} &= \frac{TP}{TP + FP}, \\ \text{莘莘学子} &= \frac{TP}{TP + FN}, \\ \text{Spe...} &= \frac{TN}{\bar{A}\bar{A}\bar{A} TN}, \\ \text{F1...} &= \frac{2 \times \text{Pre} \times \text{Sen}}{\text{前期} + \text{后期}} \end{aligned} \quad (6)$$

其中，TP（真阳性）是指被正确识别为异常的脑电图记录的数量；TN（真阴性）是指被正确预测为正常的脑电图案例的数量；FP（假阳性）是指被预测为异常的正常脑电图案例的数量；FN（假阴性）是被错误地分类为正常的异常脑电图记录的数量。

为了减少由小规模测试数据集引起的测试误差测定的统计不确定性，我们采用了10

折叠交叉验证法进行评估。2300个EEG信号的

每个类别都被随机分为十个不重叠的折叠。在*第i*次测试中，EEG信号的*第i*个折线是

用于测试，而其余9个折页则用于

训练。文中报告的准确度、灵敏度和规格值是由10次评估得到的平均值。

3. 实验结果和讨论

数据集以不同的组合进行分组，以体现一般的分类模型，分为两类（非癫痫和癫痫发作）、三类（正常、发作间期和发作）和五类（A、B、C、D和E）。为了选择更好的模型参数，我们考虑了8个具有不同构架的模型。

3.1. **模型的选择。**我们探索了具有不同参数的模型，包括感受器的大小、神经元的数量和FC层的退出概率，以进行比较。以五类分类问题为例，使用10倍交叉验证的实验结果见表2。

实验表明，在实验参数范围内，更大的感受场和更多的神经元在FC层使识别更有效。FC层中20%的辍学概率比50%的辍学率更有效。因此，模型M7的参数与

表2：对A与B与C与D与E的案例使用10倍交叉验证的8个模型的构架。

| 块状 | 参数 | M1 | M2 | M3 | M4 | M5 | M6 | M7 | M8 |
|-------------------|--------|-------|-------|-------|-------|-------|-------|-------|-------|
| Conv 1感受区的大小 | 果核数量 | 20 | 20 | 20 | 20 | 20 | 20 | 20 | 20 |
| | | 5 | 5 | 5 | 5 | 40 | 40 | 40 | 40 |
| | 辍学率 | 0.2 | 0.2 | 0.2 | 0.2 | 0.2 | 0.2 | 0.2 | 0.2 |
| Conv 2感受区的大小 | 果核数量 | 40 | 40 | 40 | 40 | 40 | 40 | 40 | 40 |
| | | 3 | 3 | 3 | 3 | 20 | 20 | 20 | 20 |
| | 辍学率 | 0.2 | 0.2 | 0.2 | 0.2 | 0.2 | 0.2 | 0.2 | 0.2 |
| Conv 3感受区的大小 | 果核数量 | 80 | 80 | 80 | 80 | 80 | 80 | 80 | 80 |
| | | 3 | 3 | 3 | 3 | 10 | 10 | 10 | 10 |
| | 辍学率 | 0.2 | 0.2 | 0.2 | 0.2 | 0.2 | 0.2 | 0.2 | 0.2 |
| FC 1 | 神经元的数量 | 32 | 32 | 64 | 64 | 32 | 32 | 64 | 64 |
| | 辍学率 | 0.2 | 0.5 | 0.2 | 0.5 | 0.2 | 0.5 | 0.2 | 0.5 |
| FC 2 | 神经元的数量 | 16 | 16 | 32 | 32 | 16 | 16 | 32 | 32 |
| | 辍学率 | 0.2 | 0.5 | 0.2 | 0.5 | 0.2 | 0.5 | 0.2 | 0.5 |
| A 对 B 对 C 对 D 对 E | 帐户 | 90.47 | 88.61 | 91.89 | 91.20 | 93.37 | 91.62 | 93.55 | 92.92 |
| | 参 | 75.98 | 70.86 | 79.66 | 77.79 | 83.33 | 78.85 | 83.73 | 82.30 |
| | 斯佩 | 94.00 | 92.72 | 94.92 | 94.45 | 95.83 | 94.71 | 95.93 | 95.57 |

在两类和三类分类的实验中，采用了不同组合的最佳性能。

3.2 拟议模型的性能。多重分类问题可以被分解成多个二元分类问题。每个分类的结果都可以被列为混淆矩阵，它反映了每个类别的原始和预测的标签。表3显示了混淆矩阵和分类正常（B）与发作前（D）与发作（E）的评估指标，以及整体分类结果。所有的指标都超过了96%，特别是规格化，在每个类别中都超过了98%，总体分类也是如此。

为了检查所提出的模型的稳健性，我们测试了20个组合。表4显示了10倍交叉验证结果的细节，其中平均精度被用作总体精度。两类分类的准确率从97.63%到99.52%不等，其中A与E的表现最好，D与E的表现最差。五类分类问题比二类和三类问题更复杂，更难解决，但在众多临床应用中具有优势，所提出的模型仍然获得了93.55%的总体准确率。所提出的模型适用于波恩数据集的各种分类问题，具有很强的泛化能力。

3.3 与以往研究的比较。文献中提出了许多使用波恩EEG数据库自动检测癫痫发作的方法。表5显示了这项工作与它们在各种分类问题上的识别率的比较结果。二元分类问题是指识别非癫痫发作和癫痫发作的问题。健康志愿者和癫痫发作的分类是A与E，B与E，以及AB与E。

E.由于这种分类方法的显著差异，表5中出现的各种方法的分类结果普遍很出色，都在99%以上。发作间期和发作期（C与E、D与E、CD与E）的分类准确率比第一次二元分类略低。特别是，D和E两组都是来自致病区；因此，很难区分。在表5的传统方法中，Zhang等人[1]获得了最好的性能，其准确率达到98.1%。在基于CNN的技术中，Ullah等人[2]采用CNN和多数票模块进行分类，获得99.4%的准确率。Turk和Ozerdem[17]使用CWT和CNN进行识别，获得98.50%的准确率。本研究提出的模型只采用了CNN，获得了97.63%的准确率。

三类分类问题将脑电图记录进一步细分，以区分正常、发作间期和发作期脑电图。我们比较了两种类型的三类问题（B与D与E和AB与CD与E）。提出的模型也取得了良好的性能。特别是在B vs. D vs. E的情况下，其表现达到了98.06%的最佳准确率，这明显优于另一个仅基于CNN的模型[16]。

五类分类问题比二类和三类问题更复杂，更难分类。它需要识别属于同一类别的EEG epochs之间的差异（例如，A组和B组，都是正常的；C组和D组，都是发作间歇的）。因此，在文献中，提出了相对一些方法来同时解决这三类问题。所提出的CNN模型达到了93.55%的准确率，这与Turk和Ozerdem[17]的结果非常接近，也优于传统方法。

实验中仍需实施重新提高学习率和增加epochs的数量，这无疑会提高癫痫识别的准确性，但同时也会花费更多的时间进行训练。对于数量有限的训练样本。

表3：三类问题（B与D与E.）的混淆矩阵，跨越10个折页。

| | | 正常 | 预测的 前列症状 | 癫痫发 作 | 帐户 | 莘莘 学子 | 斯佩 | 前期 | F1 |
|------|----------|------|-------------|----------|-------|----------|-------|-------|-------|
| 原创 | 正常 | 2263 | 36 | 1 | 98.32 | 98.39 | 98.28 | 96.63 | 97.50 |
| | 发作前 | 49 | 2220 | 31 | 97.54 | 96.52 | 98.04 | 96.10 | 96.31 |
| | 癫痫发 作 | 30 | 54 | 2216 | 98.32 | 96.35 | 99.30 | 98.58 | 97.45 |
| 总的来说 | | - | - | - | 98.06 | 97.09 | 98.54 | 97.10 | 97.09 |

表4：使用M7模型进行10倍交叉验证的准确率（%）。

| 数据集的组合 | K1 | K2 | K3 | K4 | K5 | K6 | K7 | K8 | K9 | K10 | 平均值 |
|-------------------|-------|-------|-------|-------|-------|-------|-------|-------|-------|-------|-------|
| A对E | 100 | 99.57 | 99.57 | 99.35 | 99.35 | 99.57 | 99.13 | 99.57 | 99.35 | 99.78 | 99.52 |
| B对E | 99.78 | 99.13 | 99.57 | 98.91 | 99.13 | 99.35 | 98.70 | 98.70 | 98.70 | 99.13 | 99.11 |
| C对E | 99.35 | 98.04 | 98.04 | 96.96 | 98.26 | 97.39 | 97.39 | 97.83 | 98.48 | 98.48 | 98.02 |
| D对E | 97.61 | 98.04 | 98.26 | 98.04 | 97.17 | 98.04 | 96.52 | 97.17 | 96.52 | 98.91 | 97.63 |
| AB对E | 99.57 | 99.13 | 99.57 | 99.57 | 99.57 | 99.13 | 99.57 | 99.13 | 99.57 | 98.99 | 99.38 |
| AC对E | 99.28 | 98.70 | 99.13 | 98.84 | 99.13 | 98.70 | 98.99 | 99.57 | 99.42 | 98.55 | 99.03 |
| AD vs. E | 98.12 | 97.83 | 98.41 | 98.70 | 98.41 | 98.41 | 98.55 | 98.55 | 99.13 | 98.84 | 98.50 |
| BC对E | 98.70 | 98.41 | 97.68 | 98.55 | 98.55 | 98.99 | 98.84 | 99.28 | 99.57 | 98.26 | 98.68 |
| BD vs. E | 97.39 | 97.10 | 97.54 | 98.84 | 98.26 | 97.54 | 98.41 | 97.97 | 97.83 | 97.39 | 97.83 |
| CD对E | 97.68 | 97.54 | 98.41 | 97.83 | 98.41 | 97.25 | 98.84 | 98.41 | 97.97 | 97.97 | 98.03 |
| ABC VS. E | 99.24 | 98.26 | 99.24 | 98.91 | 98.80 | 99.02 | 98.91 | 99.24 | 98.91 | 98.37 | 98.89 |
| ABD vs. E | 98.80 | 98.37 | 98.80 | 98.26 | 98.80 | 99.35 | 98.48 | 97.93 | 98.15 | 98.26 | 98.52 |
| BCD与E | 98.26 | 97.61 | 98.59 | 98.26 | 98.59 | 99.24 | 98.04 | 98.70 | 97.93 | 98.37 | 98.36 |
| ABCD对E | 98.96 | 99.22 | 98.70 | 98.52 | 98.35 | 99.22 | 98.78 | 98.61 | 99.13 | 98.09 | 98.76 |
| A对C对E | 96.04 | 97.05 | 97.00 | 97.39 | 94.98 | 97.58 | 97.00 | 96.09 | 96.81 | 97.39 | 96.73 |
| A对D对E | 97.63 | 97.10 | 97.54 | 95.94 | 97.00 | 96.67 | 97.39 | 97.87 | 96.81 | 96.43 | 97.04 |
| B对C对E | 97.63 | 97.97 | 98.12 | 97.68 | 98.36 | 97.20 | 97.87 | 99.03 | 97.68 | 97.58 | 97.91 |
| B对D对E | 98.35 | 98.30 | 98.07 | 97.49 | 98.26 | 97.97 | 97.20 | 98.45 | 98.45 | 98.06 | 98.06 |
| AB vs. CD vs. E | 96.70 | 97.10 | 97.74 | 96.43 | 96.72 | 97.97 | 94.96 | 97.91 | 96.96 | 97.25 | 96.97 |
| A 对 B 对 C 对 D 对 E | 92.99 | 94.37 | 94.00 | 93.41 | 93.36 | 92.73 | 93.74 | 93.25 | 93.74 | 93.91 | 93.55 |

表5：使用相同的数据集，建议的方法与其他方法的比较。

| 数据集组合方法 | | 研究Acc (%) | Our Acc(%) | TFA +ANN |
|---------|--|-------------------|------------|----------|
| A对E | | Tzallas et al.[4] | 100 | |
| | DWT + Kmeans + MLPNNOrhan等人[6]。 | | 100 | |
| | 1-D-枸杞+FT/BNKaya等人[8] | 99.50 | | |
| | DWT + NB/KNNSharmila和Geethanjali[10]。 | | 100 | 99.52 |
| | TQWT + KNNE + SVMBhattacharyya等人[11]。 | | 100 | |
| | LMD + GA-SVMZhang和Chen[1]。 | | 100 | |
| | CNN + M-VUllah等人[2]。 | 100 | | |
| | CWT + CNNTurk和Ozerdem [17]。 | | 99.50 | |
| B对E | DWT + NB/KNNSharmila和Geethanjali [10]。 | | 99.25 | |
| | TQWT + KNNE + SVMBhattacharyya等人[11]。 | | 100 | 99.11 |
| | CNN + M-VUllah等人[2]。 | 99.6 | | |
| | CWT + CNNTurk和Ozerdem[17]。 | | 99.50 | |
| C对E | DWT + NB/KNNSharmila和Geethanjali [10]。 | | 99.62 | |
| | TQWT + KNNE + SVMBhattacharyya等人[11]。 | | 99.50 | 98.02 |
| | CNN + M-VUllah等人[2]。 | 99.1 | | |
| | CWT + CNNTurk和Ozerdem [17]。 | | 98.50 | |
| D对E | 1-D-枸杞+FT/BNKaya等人 [8] | 95.50 | | |
| | DWT + NB/KNNSharmila和Geethanjali [10]。 | | 95.62 | |
| | TQWT + KNNE + SVMBhattacharyya等人[11]。 | | 98 | 97.63 |
| | LMD + GA-SVMZhang和Chen [1]。 | | 98.10 | |
| | CNN + M-VUllah等人[2]。 | 99.4 | | |
| | CWT + CNNTurk和Ozerdem[17]。 | | 98.50 | |

表5：续。

| 数据集组合方法 | 研究 | Acc (%) | Our |
|-------------------|--|---------|-------|
| AB vs. E | Acc(%) DWT +NB/KNN Sharmila and Geethanjali [10] | 99.16 | 99.38 |
| | CNN + M-VUllah等人[2]。 99.8 | | |
| CD对E | 1-D-枸杞+FT/BNKaya等人[8] 97.00 | 98.75 | 98.03 |
| | DWT + NB/KNNSharmila和Geethanjali [10]。 99.7 | | |
| | CNN+M-VUllah等人[2]。 99.7 | | |
| ABCD对E | DWT + Kmeans + MLPNNOrhan等人 [6] 99.60 | 97.1 | 98.76 |
| | DWT + NB/KNNSharmila和Geethanjali [10]。 99 | | |
| | TQWT + KNNE + SVMBhattacharyya等人[11]。 98.87 | | |
| | LMD+GA-SVMZhang和Chen[1] 98.87 | | |
| | CNN+M-VUllah等人[2]。 99.7 | | |
| B对D对E | CNNAcharya等人[16]。 88.7 | 98.00 | 98.06 |
| | CWT + CNNTurk和Ozerdem [17]。 98.60 | | |
| AB vs. CD vs. E | DWT + Kmeans + MLPNNOrhan等人 [6] 95.60 | 98.60 | 96.97 |
| | TQWT + KNNE + SVMBhattacharyya等人[11]。 98.40 | | |
| | LMD + GA-SVMZhang和Chen[1] 98.40 | | |
| | CNN + M-VUllah等人[2]。 99.1 | | |
| A 对 B 对 C 对 D 对 E | TFA + ANNTzallas等人[4]。 89 | 93.60 | 93.55 |
| | MEMD+ANNZahra等人[12]。 87.2 | | |
| | CWT + CNNTurk和Ozerdem [17]。 93.60 | | |

我们还可以尝试加强数据集，这对模型的泛化能力可能是有用的。例如，我们可以把23.6秒的脑电图数据分成许多超长的块，以进一步增加样本的数量。

4. 总结

我们提出了一种用于稳健检测癫痫发作的新型模型，它可以处理二类、三类和五类分类问题。所提出的方法是在一维卷积神经网络模型的基础上开发的，该模型将原始脑电信号作为输入。为了提高模型的学习能力，在传统的卷积块中引入了BN和dropout层。为了解决小数据集的问题，脑电图被分成许多非过度的块状物进行训练和测试。实验结果表明，该模型在波恩数据集的各种脑电分类问题上表现良好。

数据可用性

用于支持本研究结果的数据可向相应作者索取。

利益冲突

作者声明，他们没有利益冲突。

鸣谢

这项工作得到了福建省中青年教育科研项目（JAT191153和JT180872）、国家自然科学基金（上海）的支持。

(课题组成员包括：中国科学院院士、中国工程院院士、中国工程院院士、中国工程院院士、中国工程院院士、中国工程院院士、中国工程院院士、中国工程院院士、中国工程院院士、中国工程院院士等。

参考文献

[1] T.Zhang and W. Chen, "LMD based features for the automatic seizure detection of EEG signals using SVM," *IEEE Transactions on Neural Systems and Rehabilitation Engineering*, vol. 25, no. 8, pp. 1100-1108, 2017.

[2] I.I. Ullah, M. Hussain, E.-U.-H.Qazi, and H. Aboalsamh, "An automated system for epilepsy detection using EEG brain signals based on deep learning approach," *Expert Systems with Applications*, vol. 107, pp. 61-71, 2018.

[3] H.Ocak, "Automatic detection of epileptic seizures in EEG using discrete wavelet transform and approximate entropy," *Expert Systems with Applications*, vol. 36, no. 2, pp. 2027-2036, 2009.

[4] A.T. Tzallas, M. G. Tsipouras, and D. I.Fotiadiis, "Epileptic seizure detection in EEGs using time-frequency analysis," *IEEE Transactions on Information Technology in Biomedicine*, vol. 13, no.5, pp. 703-710, 2009.

[5] A.Subasi andM. Ismail Gursay, "使用PCA、ICA、LDA和支持向量机进行脑电信号分类", *专家系统与应用*, 第37卷, 第12期, 第8659-8666页, 2010年。

[6] U.Orhan, M. Hekim, and M. Ozer, "EEG信号分类使用K-means聚类 and 多层感知器神经网络模型," *Expert Systems with Applications*, vol. 38, no. 10, pp. 13475-13481, 2011.

[7] U.R. Acharya, F. Molinari, S. V. Sree, S. Chattopadhyay, K. -H.Ng, and J. S. Suri, "Automated diagnosis of epileptic EEG using entropies," *Biomedical Signal Processing and Control*, vol. 7, no.4, pp. 401-408, 2012.

[8] Y.Kaya, M. Uyar, R. Tekin, and S. Yildirim, "1D-local binary pattern based feature extraction for classification of epileptic EEG signals," *Applied Mathematics and Computation*, vol. 243, pp. 209-219, 2014.

- 本质模式函数, " *Expert Systems with Applications*, vol. 42, no.3, pp. 1106-1117, 2015.
- [10] A.Sharmila and P. Geethanjali, "DWT based detection of epileptic seizure from EEG signals using naive bayes and k-NN classifiers," *IEEE Access*, vol. 4, pp. 7716-7727, 2016.
 - [11] A.Bhattacharyya, R. Pachori, A. Upadhyay et al., "Tunable-Q wavelet transform based multiscale entropy measure for automated classification of epileptic EEG signals," *Applied Sciences*, vol. 7, no.4, Article ID 385, 2017.
 - [12] A.Zahra, N. Kanwal, N. ur Rehman, S. Ehsan, and K.D. McDonald-Maier, "Seizure detection from EEG signals using multivariate empirical mode decomposition," *Computers in Biology and Medicine*, vol. 88, pp. 132-141, 2017.
 - [13] Y.LeCun, Y. Bengio, and G. Hinton, "Deep learning," *Nature*, vol. 521, no. 7553, pp.436-444, 2015.
 - [14] C.Huang, Y. Lan, G. Xu等, "A deep segmentation network of multi-scale feature fusion based on attention mechanism for IV OCT lumen contour," *IEEE/ACM Transactions on Computational Biology and Bioinformatics*, 2020.
 - [15] M.Li, S. Dong, Z. Gao等, "Uni-fied model for interpreting multi-view echocardiographic sequences without temporal information," *Applied Soft Computing*, vol. 88, Article ID 106049, 2020.
 - [16] U.R. Acharya, S. L. Oh, Y. Hagiwara, J. H. Tan, and H. Adeli, "Deep convolutional neural network for the automated detection and diagnosis of seizure using EEG signals," *Computers in Biology and Medicine*, vol. 100, pp. 270-278, 2018.
 - [17] O.Turk和M. S. Ozerdem, "Epilepsy detection by using scalogram based convolutional neural network from EEG signals," *Brain Sciences*, vol. 9, no.5, Article ID 115, 2019.
 - [18] R.Hussein, H. Palangi, R. K. Ward, and Z. J. Wang, "Optimized deep neural network architecture for robust detection of epileptic seizures using EEG signals," *Clinical Neurophysiology*, vol. 130, no. 1, pp. 25-37, 2019.
 - [19] R.G. Andrzejak, K. Lehnertz, F. Mormann等人, "脑电活动时间序列中的非线性确定性和二维结构的迹象：对再记录区域和大脑状态的依赖", 《物理评论E》, 第64卷, no. 6, 文章ID 061907, 2001。
 - [20] Y.LeCun, "泛化和网络设计策略", 在《透视连接主义》中, 第143-155页, Elsevier, 苏黎世, 瑞士, 1989。
 - [21] V.Nair 和 G. E. Hinton, "Rectified linear units improve restricted Boltzmann machines," in *Proceedings of the International Conference on Machine Learning (ICML)*, pp.807-814, Haifa, Israel, June 2010.
 - [22] N.Srivastava, G. Hinton, A. Krizhevsky等人, "Dropout: a simple way to prevent neural networks from overfitting," *Journal of Machine Learning Research*, vol. 15, no. 1, pp.1929-1958, 2014.
 - [23] S.Ioffe和C. Szegedy, "Batch normalization: accelerating deep network training by reducing internal covariate shift," in *Proceedings of the 32nd International Conference on International Conference on Machine Learning*, vol. 37, pp. 448-456, Lille, France, July 2015.