

期刊预检

利用叠加的双向长短时记忆检测和预测癫痫发作

D K Thara , B G PremaSudha , Fan Xiong PII:

S0167-8655(19)30312-5

DOI。

<https://doi.org/10.1016/j.patrec.2019.10.034>

参考资料。

PATREC 7682



将出现在: *模式识别通讯》杂志*

收件日期 : 2019年9月 15日

修订日期 : 2019年10月 22日

接受日期:2019年10月 29日

请将本文引用为:D K Thara , B G PremaSudha , Fan Xiong , Epileptic Seizure Detection and Prediction using Stacked Bidirectional Long Short Term Memory, *Pattern Recognition Letters* (2019), doi: <https://doi.org/10.1016/j.patrec.2019.10.034>

这是一篇文章的PDF文件, 该文件在被接受后进行了改进, 如增加了封面和元数据, 并进行了可读性的格式化, 但它还不是最终的记录版本。这个版本在以最终形式出版前还会经过额外的文字编辑、排版和审查, 但我们提供这个版本是为了让大家尽早看到这篇文章。请注意, 在制作过程中, 可能会发现可能影响内容的错误, 所有适用于本刊的法律免责声明都适用。

© 2019年由Elsevier B.V.出版。

亮点

- 利用脑电图进行癫痫发作检测和预测。
- 双向长短期记忆被用于检测和预测。
- 精度、召回率和ROC AUC被用来评估模型的性能。
- 取得了AUC的结果。0.9，用于检测癫痫发作。
- 对癫痫发作预测的敏感度为89.21%。

利用叠加的双向长短时记忆检测和预测癫痫发作

Thara D K^{a,*}, B G PremaSudha^b, and Fan Xiong^c^a 卡纳塔克邦图马库鲁CIT的ISE部门助理教授^b 卡纳塔克邦图马库鲁, SIT, CSE部, 研究指南^c 美国加州Bio-Rad实验室生命科学组电气工程师

*通讯作者的电子邮件地址: tarakmurthy10@gmail.com

ABSTRACT

癫痫不是一种疾病，而是一种神经系统疾病。但癫痫患者不能像其他人一样过社会生活。适当的对癫痫发作的诊断和提前预测肯定会改善癫痫患者的生活。本文努力开发一种使用堆叠双向长短期记忆技术的癫痫发作检测和预测方法。这是最适合分析时间序列数据集的技术，因为它克服了循环神经网络中的梯度消失问题。用于检测和预测实验的数据集取自波恩大学。我们的模型能够以最高的准确率99.08%进行癫痫检测，精确度98%，召回率99.5%，ROC AUC:0.984346。AUC超过0.9的二元分类方法被认为是优秀的。使用相同的数据集进行癫痫发作预测，将脑电图的发作前状态从发作间歇期和发作期状态分类。对于预测的情况，我们的模型可以识别出发作前的状态，总体灵敏度为89.21%，错误预测率为0.06。0.06。在未来，该模型可用于可穿戴设备的编程，如腕式手表，可供癫痫患者用于癫痫发作预测。该设备可以被编程为在癫痫发作前检测到发作前的脑电信号时发出警报。

关键词。癫痫，发作，LSTM，检测，预测，深度学习。

1 简介

癫痫患者是唯一真正了解他们在生活中因反复发作而经历痛苦的人。他们不能像其他普通人一样过社会生活。他们所承受的精神上的期待和发作时的不确定性，比他们在发作时遭受的尴尬和伤害更令人紧张[1][2]。不受控制的癫痫发作有时也可能导致突然的意外死亡。诊断癫痫病是一个很大的挑战。即使在今天，神经科医生也是依靠对脑电图信号的人工分析以及对病人的视频监控来诊断癫痫病。为了准确诊断，必须对以下情况进行记录

2天3天甚至一个星期。人工分析如此庞大的记录是一个费力的过程。因此，非常需要自动检测方法来帮助神经病学家进行正确的诊断。几十年来，自动检测方法的发展一直在进行。许多研究人员在这方面提出了各种方法。每年都有更准确的方法被确定用于诊断癫痫。到目前为止，研究人员已经使用了许多统计方法和脑电图特征提取技术，如小波变换[3]、傅里叶变换[4]、原理成分分析[5]等，以及许多机器精益方法，如支持向量机、决策树、天真贝叶斯、随机森林等进行分类。如今，深度学习方法正在获得更多的关注，并在各个领域取得了令人印象深刻的成果。在本文中，我们努力使用深度学习[6][7]来实现良好的癫痫检测和预测方法。

由于癫痫发作是一种危险的活动，因此，在实际发生之前，通过某种方式获得有关癫痫发作的小提示，对癫痫患者来说是非常重要的。这有助于他们在癫痫发作之前采取一些预防措施。发作检测和预测是研究中最具挑战性的课题之一。发作预测已成为许多研究人员的目标。预测癫痫发作最常用的工具是脑电图（EEG）[8][9][10]。发作检测和预测都可以使用脑电图数据进行。这是使用最广泛的工具，也是能够帮助明确区分大脑的不同状态的工具。

脑电信号的振幅水平[11]表示每个时间步骤释放的电压水平。脑电图信号中有四种状态被确认。它们是发作间歇、发作前、发作中和发作后状态[12][13]。所有这四种状态下的信号的电压水平是不同的。发作间歇状态是指在癫痫发作时发生的状态。发作前状态是发生在发作前几分钟的状态。发作间期是指两个连续的发作之间的状态。发作后状态是指发作发生后的状态。根据这些知识，我们可以理解，为了检测癫痫发作，我们需要从脑电信号的所有其余状态中对发作状态进行分类，为了预测癫痫发作，我们需要从发作间期和发作状态中对发作前状态进行分类。癫痫发作检测方法必须识别是否有正在进行的癫痫发作。该方法可以是二元分类；对发作或不发作进行分类，也可以是更精细的分类；对发作间期、发作前、发作或发作后进行分类。但在多类分类的情况下，由于“维度诅咒”，模型的性能会降低。因此，在本实验中，我们开发了一种二元分类方法。

癫痫病人在发作前会处于前驱状态。因此，需要确定癫痫病人的发作前状态。

这样就有可能通过某种方式向病人提供一些关于癫痫发作症状的提示，例如以可穿戴设备的形式[8]，如图1所示的腕式手表，当识别到发作前的状态时可以发出警报。通过这种方式，可以用药物避免癫痫发作，病人也可以避免危险活动，如开车、游泳、在路边行走等[14][15][16]。

癫痫检测和预测是一项具有挑战性的持续研究，即使在今天[17]。尽管在这个问题上已经进行了大量的研究，但即使在今天，许多神经病学家仍然依赖于人工诊断，因为他们对计算机化的方法没有信心。不可能有完美的方法或完美的检测或预测模型。但只能有能够发现的最佳模型。本文试图利用双向长短期记忆（LSTM）技术，开发一种能够保证癫痫发作检测和预测的良好准确性的方法。

LSTM源于递归神经网络。递归神经网络是一种用于分析连续数据的神经网络类型。在传统的神经网络中，输入数据的每个实例被认为是相互独立的。而在顺序数据的情况下，一个时间步骤的输出取决于前一个时间步骤的输出。因此，在RNN中，每个时间步骤的输出与下一个时间步骤的新输入一起被提供为输入。这些递归神经网络是用时间反向传播（BPTT）来训练的。BPTT存在梯度消失和梯度爆炸的问题。LSTM是专门为解决RNN的消失和爆炸梯度问题而设计的架构。在这项工作中，我们开发了一种使用堆叠式双向LSTM进行癫痫检测和预测的方法。

在未来，所开发的癫痫预测模型可以被编程到可穿戴设备上[8]，如图1所示的腕式手表。该设备可以被编程为在识别出预发状态时向病人发出警报。该设备必须在癫痫发作前至少几分钟发出警报。为此，应定义一个预测时间区。如果警报在发作前的预测时间段内发生，那么它就被认为是真正的警报。如果警报发生在预测时间区之前，那么它被视为假警报。如果警报既不发生在预测时间段之前，也不发生在预测时间段之内，也不发生在癫痫发作之前，那么它将被视为假阴性警报。下面的图2说明了更多关于癫痫预测报警的情况。图2a显示了在癫痫发作前几分钟发射的真阳性警报的情况。图2b显示了在预测时间区之前发射假阳性警报的情况。图2c显示没有警报发射，这是假阴性警报的情况。



图1：腕式手表。癫痫患者的可穿戴设备，在发作前的状态下发出警报[8]。

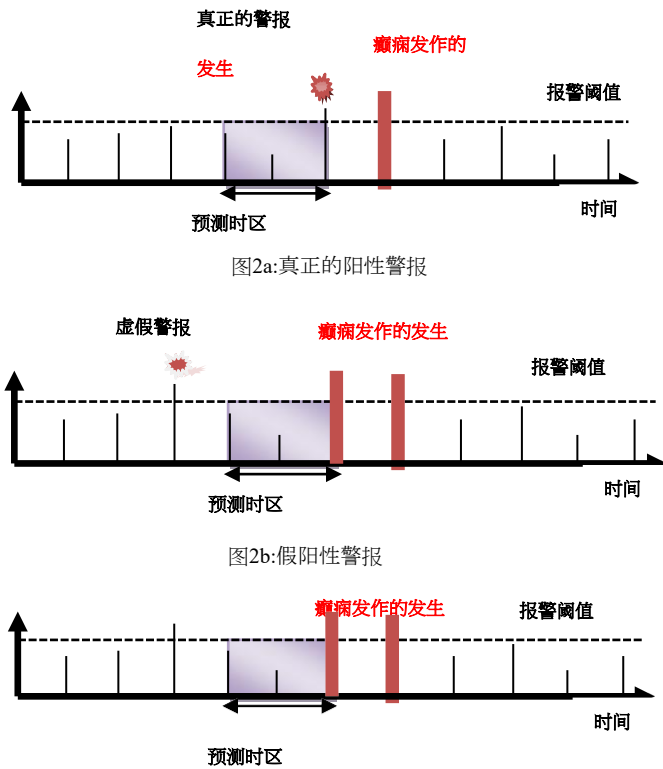


图2a:真正的阳性警报

图2b:假阳性警报

图2c:虚假的负面警报

图2：癫痫发作的预测警报

1.1. 激励

来自PRL的论文对我们这样即将到来的研究人员来说是很大的鼓舞。其中一篇激励我们的PRL论文是Rakesh Ranjan等人的 "A Fuzzy Neural Network Approach for Automatic K- Complex Detection in Sleep EEG Signal" [20]。该团队在开发K-复合体自动检测器方面做出了杰出的研究工作。他们根据EEG信号进行了详细的睡眠分析。他们在实验中使用了模糊神经网络方法；模糊c-means算法和反向传播算法来快速检测k-complex。为了分类，他们使用了3种线性模型，如1层前馈神经网络、Logistic回归和SVM。还有2种非线性模型，如多层前馈神经网络和SVM。他们使用了在睡眠状态下记录的2小时的脑电信号。记录的信号包括来自电源线干扰的伪影。他们通过应用数字陷波滤波器去除伪影。第二阶段的脑电信号是用带通滤波器提取的。第三阶段的EEG信号使用Savitzky-Golay滤波器进行平滑化。平滑化后的EEG信号被提供给模糊C-means算法作为输入。他们使用最大/最小振幅和时间周期等特征，将脑电信号分为k-复杂和非k-复杂。进一步将k-复合信号作为输入给神经网络，使用反向传播算法进行性能评估。通过计算准确性、敏感性和特异性来进行评估。这项工作显示了k-复合体检测的惊人结果。感谢该团队在生物医学信号处理领域做出了如此卓越的贡献。该论文由7个部分组成；组织得非常整齐。它写得很有系统，易于理解。[20]中的作者向我提供了他们论文的源代码。我使用了他们的实现，并在我的测试案例中验证了它。他们的方法在我所有的测试案例中都给出了很好的结果。这篇论文提供了完整的实验流程的一步描述。

1.2.相关工作

癫痫发作的检测和预测是一项持续的研究。到目前为止，一些研究人员已经尝试使用机器学习和深度学习的许多不同方法[19][21]来预测癫痫发作[22][23]。其中一些是，Xuelin Ma等人

[24]使用了一个基于长短期记忆和多任务学习的框架来预测癫痫发作。他们使用LSTM进行顺序数据处理，使用多任务学习进行预测。他们获得了预测准确率：89.36%。他们使用的数据集包括两个病人的数据，分别有263和210个样本。他们使用Keras框架来实现神经网络。他们使用优化函数Adam，学习率为0.5，密集层由128个节点组成，隐藏层共有32个stm单元。

MINGRUI

SUN等人[25]利用深度学习算法对癫痫发作进行了预测。他们使用傅里叶变换方法将时域信号转换为频域信号。使用两层卷积神经网络提取时域和频域信号，使用四种不同的方法（2种线性模型方法和2种深度学习方法）进行发作预测。颅内EEG数据包括2条犬和2个人的数据。犬类的的数据以400赫兹采样，2人的数据以5000赫兹采样。线性模型下的两种方法是。1.线性判别分析和2：线性回归。对于深度学习

他们使用了1.卷积神经网络和2.循环神经网络。最后，他们对这两种类型的模型进行了比较，并得出结论：卷积神经网络通过提供最佳的AUC性能指标，超过了所有其余的方法。

Ahmed

M.

Abdelhameed等人[26]尝试使用深度学习方法对癫痫发作进行早期检测。卷积自动编码器被用来提取未标记的原始EEG数据的空间特征，并使用lstm的递归神经网络进行分类。他们使用转移学习方法初始化了权重。在1小时的预测窗口中，他们的模型成功地提供了94%的预测准确性。

在这一领域没有取得良好进展的原因是没有具有明确定义的训练集和测试集的数据集。美国癫痫协会在kaggle.com上公开提供了8只狗的26小时颅内EEG数据。该数据集由预定义的训练集、验证集和测试集组成，目的是帮助研究人员直接评估各种算法的结果。Iryna

Korshunova等人[相关8]使用了这个数据集，提供给癫痫预测挑战。他们研究了三种不同的方法：SVM、LDA和CNN。其中CNN表现最好，AUC分数最高。

Carlos

Emiliano

Sol'orzano-

Esp'indola等人[11]使用高斯混合模型隐马尔科夫模型对小儿癫痫发作预测进行了尝试。他们使用带通滤波器对数据进行了预处理，选择带通黄油值滤波器来去除数据中的生物噪声，并使用巴特沃斯陷波滤波器去除电力线的噪声。他们使用主成分分析技术进行降维。他们从EEG数据中提取了熵、Teager-Kaiser能量和Kurtosis等特征。最后，他们使用GMM-HMM模型进行分类。结果显示灵敏度为95%，特异性为86%。

预测任务来自单元存储器。这是通过在和输入门之间进行点乘运算来实现的。

of the amount of input data entering the network at each time step. It is responsible for adding the information into the cell state. It adds only the information required for the prediction and stops all redundant and unwanted data entering into the cell memory. This is obtained by performing dot product operation between input gate vector and tanh layer vector. Finally, 输出门是

输出门将跟踪内存中多少内容对任务有用, 并只输出这部分信息作为当前细胞状态的输出 ()。它使用激活函数tanh来转换当前细胞状态向量的值, 使其在-1到+1的范围内。这些转换后的值与输出门sigmoid激活向量进行点乘运算。得到的向量被认为是细胞在时间步骤t的最终输出 ()。实验中使用的算法如下图4所示。

- 导入依赖关系
- 数据预处理
- 将数据集划分为训练集和测试集。
- 使用合适的特征缩放技术对数据集进行特征缩放。
- 重塑X
- 创建模型; 定义输入层、隐藏层和输出层的单元数量。
- 编译模型
- 选择训练窗口大小并相应地组织数据集。
- 对于no_of_epochs和batchsize做
 - 使用训练集训练网络
 - 结束
- 使用验证集对网络进行评估。
- 计算训练集和验证集的准确性和损失函数。
- 图形可视化

图4：拟议的LSTM模型的算法

从大脑中记录的EEG信号在本质上是连续的。而LSTM在分析连续数据集方面表现良好, 因此LSTM是适合使用脑电信号进行癫痫检测和发作预测的最佳技术。在我们的实验中, 使用了堆叠的双向LSTM, 图5中显示了相同的情况。

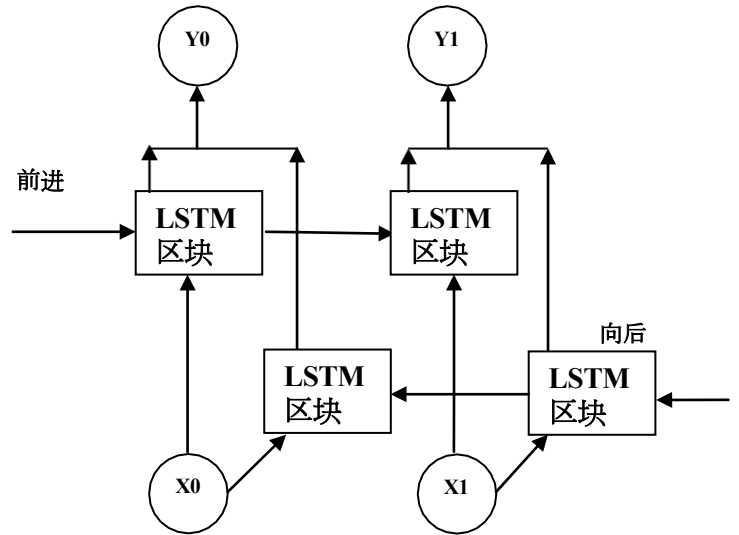


图5：两层叠加的双向LSTM

2.2. 拟议模式

实验使用Keras、Numpy、Tensorflow、Sklearn和Matplotlib进行。作为第一步, 对由500人的178个数据点组成的数据集进行了可视化。下面的图6显示了数据集中发作事件的直观情况, X轴为时间, Y轴为微伏的振幅。第5行和第4行代表健康信号, 第3行和第2行代表发作间期信号, 第1行表示癫痫发作事件。




图6：数据集中癫痫发作事件的直观

拟议模型的结构如图7所示。该模型由堆叠的(2层)双向LSTM层、辍学层和密集层组成。激活函数 "tanh" 被用于隐藏层, "softmax" 被用于输出层。优化器函数 "adam" 用于优化。完整模型的摘要显示在下面的表1中。该模型总共处理了39,549个参数。在第一层lstm上评估的参数数量为12992, 第二层的参数为25312, 输出层为105。该模型使用损失函数 "binarycrossentropy" 进行编译, 优化器 "adam"。该模型的性能是用准确性来评估的。该模型在9200个样本上进行了训练, 并在2300个样本上进行了测试, 使用了50个epochs和批量大小为15。

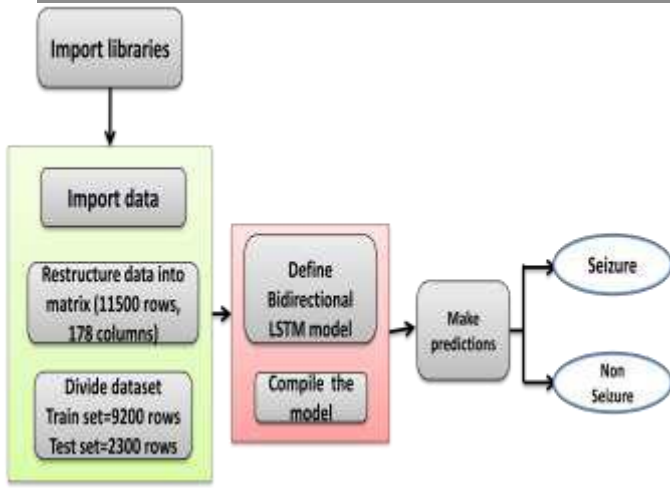


图7：拟议工作的架构 表1：模型的摘要

层(类型)	输出Shape	Param #
lstm_49 (LSTM)	(无, 45, 56)	12992
dropout_44 (辍学)	(无, 45, 56)	0
lstm_50 (LSTM)	(无, 56)	25312
dropout_45 (辍学)	(无, 56)	0
dense_29 (密集)	(无, 20)	1140
activation_29 (激活)	(无, 20)	0
dense_30 (密集型)	(无, 5)	105
activation_30 (激活)	(无, 5)	0

总参数。39,549

可训练的参数。39,549

不可训练的参数。0

3. 结果与讨论

本节介绍了该模型的结果。双向LSTM模型被执行来进行癫痫检测。这是一个二元分类问题。输入的样本被分为癫痫发作事件或非癫痫发作事件。图8显示了训练集和测试集的分类准确性。图9显示了所提出的LSTM模型的训练集和测试集的损失。训练集的准确率为99.89%，测试集为99.08%。




图8：模型在训练集和测试集之间的准确度图。




图9：模型在训练集和测试集之间的损失图。

表2给出了所提出的LSTM模型在训练集和测试集的准确率、精确度、召回率和F1得分。表3给出了建议的工作与最新发表的工作的比较。

表2：测试集和训练集的性能指标

参数	测试组	分数
准确度	测试组	0.91
	火车组	0.93
精度	测试组	0.95
	火车组	0.96
召回	测试组	0.96
	火车组	0.96
F1_Score	测试组	0.91
	火车组	0.92

性能矩阵Precision、Recall和F1_Score是用以下公式计算的。

F1_Score

表3：拟议工作与最新发表的工作的准确性比较。

	方法	准确度
马学林等人[24]	LSTM	89.36%
我们的实验	堆叠的双向LSTM	91%

上文图10所示的接受者操作特征给出了灵敏度和特异性之间的权衡。它显示了该模型对脑电图数据中的真阳性成分和假阳性成分进行分类的能力。ROC的曲线下面积（AUC）为0.984346。它给出了该模型在所有可能的阈值上的平均性能指标。一个AUC为0.5的二元分类模型被认为是诊断是否有癫痫发作的名义。在我们的实验中，我们的模型表现出色，AUC为0.984346。




图10：验证集的接收操作特性。
具有AUC。0.984346

实验中使用的数据集由5个文件夹组成，其中文件夹3和2包括在发作前和发作间期收集的数据，文件夹1包括在发作期收集的数据。在预测癫痫发作的情况下，需要将脑电图数据的发作前时期与发作间期和发作期进行分类。为了实现这一目标，再次执行模型，只考虑整个数据集中的三个文件夹（3、2和1）。这三个文件夹由300人的EEG数据组成。使用相同的模型对脑电图的发作前状态与发作间和发作状态进行分类。以下表4显示了少数受试者的敏感度和特异度。该表显示我们的模型平均可以达到89.21%的灵敏度，平均错误预测率为0.06。

表4：模型预测癫痫发作的敏感度和特异度

病人	发作次数	敏感度	特异性
P01	6	100%	0
P02	5	84.5%	0
P03	3	60%	0.2
P04	4	80%	0.1
P05	5	100%	0.08
P06	3	100%	0
P07	7	100%	0.04
共计	32	89.21	0.06

实验是在具有4GB内存、1.7GHz处理器速度的Core i5处理器的计算机系统上进行的。对于11500个样本，50个epochs和批处理大小为15的样本，需要22分钟才能完成执行。所需时间可能因计算机系统的配置不同而不同。

总结

在这个实验中，我们利用德国波恩大学的EEG数据集，提出了一种使用两层双向长短期记忆的癫痫检测和预测方法。我们的实验能够以大约99%的良好准确率检测出癫痫发作。如果一个人被检测出患有癫痫，那么帮助这些病人预测癫痫发作是非常重要的，这样他们就可以在癫痫发作之前采取适当的预防措施。因此，在这个实验中，我们也努力进行了癫痫发作预测。我们在实验中获得了约89.21%的灵敏度，成功地预测了病人的发作前状态。因此，在未来，我们希望在以下方面做出更多努力

发作预测，以帮助癫痫患者像其他人一样过正常生活。
利益冲突 无

鸣谢。

我真诚地感谢我的导师在成功进行实验过程中给予的巨大支持和协调。

参考文献

- [1] Sujitha V, Sivagami P and Vijaya M S, "Predic Epileptic Seizure from MRI Using Fast Single Shot Proximal Support Vector Machine", International Conference and Workshop on Emerging Trends in Technology- TCET, Mumbai, India, 2011.
- [2] Gonzenbach, Maurice, "Prediction of epileptic seizures using EEG data", ETHZURICH, 2015.
- [3] Duo Chen, Suiren Wan and Forrest Sheng Bao, "Epileptic Focus Localization Using Discrete Wavelet Transform Based on Interictal Intracranial EEG IEEE Transactions On Neural Systems And Rehabilitation Engineering", VOL. 25, NO.5, MAY 2017.
- [4] J.Birjandtalab, M. Heydarzadeh and M. Nourani, "Automated EEG-Based Epileptic Seizure Detection Using Deep Neural Networks", 国际医疗信息学会议，IEEE，2017年
- [5] Ye Yuan, Guangxu Xun, Kebin Jia and Aidong Zhang, "A Multi-view Deep Learning Method for Epileptic Seizure Detection using Short-time Fourier Transform", ACM 2017.
- [6] Steven Lawrence Fernandes, G. Josemin Bala, "A Novel Decision Support for Composite Sketch Matching using Fusion of Probabilistic Neural Network and Dictionary Matching", Current Medical Imaging Reviews, Vol. 13, No. 2, pp.
- [7] Mudassar Raza, Muhammad Sharif, Mussarat Yasmin, Muhammad Atique Khan, Tanzila Saba, Steven Lawrence Fernandes., "Appearance based pedestrians" gender recognition by employing stacked auto encoders in deep learning", Future Generation Computer Systems, Vol. 88, pp.28-39, 2018
- [8] Sriram Ramgopal, Sigride Thome-Souza, Michele Jackson, Navah Ester Kadish, Iván Sánchez Fernández, Jacquelyn Klehm, William Bosl, Claus Reinsberger, Steven Schachter, Tobias Lodenkemper, "Seizure detection, seizure prediction, and closed-loop warning systems in epilepsy", Epilepsy & Behavior, Elsevier, 2014
- [9] William C. Stacey, "Seizure Prediction Is Possible-Now Let's Make It Practical", EBioMedicine, Elsevier, 2016.
- [10] Matthias Eberlein, Raphael Hildebrand, Ronald Tetzlaff, Nico Hoffmann, Levin Kuhlmann, Benjamin Brinkmann and Jens Müller, "Convolutional Neural Networks for Epileptic Seizure Prediction", arxiv.org,2018.
- [11] Carlos Emiliano Sol'orzano-Esp'ndola, Blanca Tovar-Corona, A' lvaro Anzueto-R'ios, "Pediatric Seizure Forecasting using Nonlinear Features and Gaussian Mixture Hidden Markov Models on Scalp EEG Signals", 15th International Conference on Electrical Engineering, Computing Science and Automatic Control (CCE) Mexico City, Mexico September 5-7, 2018.
- [12] Parvez, Mohammad Zavid, Manoranjan Paul, "Prediction and Detection of Epileptic Seizure by Analysing EEG Signals", ResearchGate, 博士学位论文, 35-36, 2015.
- [13] Mohamad Shahbazi, Hamid Aghajan, "A GENERALIZABLE MODEL FOR SEIZURE PREDICTION BASED ON DEEP LEARNING USING CNN-LSTM ARCHITECTURE", IEEE, 2018.
- [14] Syed Muhammad Usman, Muhammad Usman and Simon Fong, "Epileptic Seizures Prediction Using Machine Learning Methods", Hindawi, Volume 2017.
- [15] Piotr W. Mirowski, Yann LeCun, Deepak Madhavan, and Ruben Kuzniecky, "Comparing SVM and Convolutional Networks for Epileptic Seizure Prediction from Intracranial EEG", IEEE, 2008.
- [16] Iryna Korshunova, Pieter-Jan Kindermans, Jonas Degraeve, Thibault Verhoeven, Benjamin H. Brinkmann Member, Joni Dambre, "Towards improved design and evaluation of epileptic seizure predictors", IEEE TRANSACTIONS ON BIOMEDICAL ENGINEERING, 2017
- [17] Yuzhen Cao, Yixiang Guo, Hui Yu, Xuyao Yu, "Eileptic seizure auto-detection using deep learning method", IEEE, 2017.
- [18] Keider Hoyos-Osorio, Jairo Castañeda-González, Genaro Daza-Santacoloma, "Automatic epileptic seizure prediction based on scalp EEG and ECG signals", IEEE, 2016.
- [19] Ramy Hussein, Hamid Palangi, Rabab Ward, Z. Jane Wang, "Eileptic Seizure Detection:A Deep Learning Approach", arxiv.org, 2018.
- [20] RakeshRanjan, RajeevArya, StevenLawrenceFernandes, ErukondaSravya, and VinayJain, "一个模糊的神经网络方法

- for Automatic K-Complex Detection in Sleep EEG Signal", Pattern Recognition Letters, Elsevier, 2017.
- [21] Ghulam Jillani Ansari, Jamal Hussain Shah, Mussarat Yasmin, Muhammad Sharif, Steven Lawrence Fernandes, "A novel machine learning approach for scene text extraction", Future Generation Computer Systems, Vol. 87, pp.328-340, 2018.
- [22] Javeria Amin, Muhammad Sharif, Mussarat Yasmin, Steven Lawrence Fernandes, "大数据分析用于脑肿瘤检测。Deep convolutional neural networks, Future Generation Computer Systems, Vol. 87, pp.
- [23] Arunkumar N, Ramkumar K., Venkatraman V., Enas Abdulhay, Steven Lawrence Fernandes, Seifedine Kadry, Sophia Segal, " Classification of focal and nonfocal EEG using entropies", Pattern Recognition Letters, Vol.94, pp.112-117, 2017.
- [24] Xuelin Ma, Shuang Qiu, Yuxing Zhang, Xiaoqin Lian and Huiguang He, "Predic Epileptic Seizures from Intracranial EEG Using LSTM-Based Multi-task Learning", Springer Nature Switzerland, A G 2018.
- [25] Mingrui Sun, Fuxu Wang, Tengfei Min, Tianyi Zang, And Yadong Wang, "Prediction for High Risk Clinical Symptoms of Epilepsy Based on Deep Learning Algorithm", IEEE Access, volume 6, 2018.
- [26] Ahmed M. Abdelhameed and Magdy Bayoumi, "Semi-supervised Deep Learning System for Epileptic Seizures Onset Prediction", 17th IEEE International Conference on Machine Learning and Applications, 2018.